

SML_Work2_411278018

April 10, 2026

第二次作品：影像資料的壓縮與重建實驗 學號：411278018

姓名：蕭本豫

作品目標：

本作品以黑白影像為資料矩陣，運用 SVD 進行矩陣分解，以達成影像檔案壓縮之目的。

1. 首先分別以 PCA 與 SVD 對單張影像矩陣進行分解，並比較 PCA 主成分與 SVD 奇異成分 (rank-q approximation) 在不同成分數量下的重建效果，藉此觀察：
 - 成份保留比例（或即壓縮倍數）與重建影像品質之間的關係，
 - PCA 與 SVD 對影像壓縮與重建之異同。
2. 接著將影像矩陣以 patch 方式切割並重新排列後，再進行 SVD 分解與奇異成分選取，以探討此類前處理是否能提升壓縮品質，並檢驗壓縮效果是否與 patch 大小相關。最後，本文將比較多張影像在不同 patch 大小與壓縮倍數下的壓縮品質表現。
3. 以 AT&T faces 的影像矩陣為例（共 40 人，每人 10 張），對該矩陣（即 400 張人臉同時）進行 SVD rank-q 近似。觀察在不同 q 值下的重建人臉品質並與原圖比較，作為將來進行人臉辨識時選擇特徵向量的依據。

預先載入套件與函數

本作品使用以下套件：- numpy：矩陣運算與線性代數（SVD、eigh）- pandas：表格整理、樣式化與結果彙整 - scipy：影像資料載入（scipy.datasets.face）、縮放（scipy.ndimage.zoom）- matplotlib：所有繪圖 - seaborn：視覺主題設定（sns.set_theme）- sklearn.datasets：載入 Olivetti Faces 資料集（僅此用途，不使用 sklearn 的分解工具）

```
[28]: # =====  
# 1. 套件引入區 (Imports)  
# =====  
import numpy as np  
import pandas as pd  
import scipy.datasets  
from scipy.ndimage import zoom  
import matplotlib.pyplot as plt  
import seaborn as sns  
from sklearn.datasets import fetch_olivetti_faces  
from skimage.metrics import structural_similarity as skim_ssim  
from typing import Optional, Union # 引入型別提示工具
```

```

# =====
# 2. 全域視覺化與排版設定 (Visualization Setup)
# =====
# 先套用 Seaborn 主題，再覆寫中文字體，避免被洗掉
sns.set_theme(style="ticks", palette="deep")

plt.rcParams.update({
    # 字體與顯示設定
    'font.sans-serif': ['PingFang TC', 'Heiti TC', 'Arial Unicode MS'],
    ↪ 'sans-serif'],
    'axes.unicode_minus': False,
    'grid.alpha': 0.4,
    'axes.labelcolor': '#333333',

    # 畫質與大小設定
    'figure.dpi': 300,
    'savefig.dpi': 300,
    'font.size': 12,
    'axes.labelsize': 14,
    'axes.titlesize': 16,
    'xtick.labelsize': 11,
    'ytick.labelsize': 11,
    'legend.fontsize': 12,
})

# 設定亂數種子
np.random.seed(42)

# =====
# 3. 核心工具函數定義 (Utility Functions)
# =====
from pandas.io.formats.style import Styler

def apply_report_theme(styler: Styler) -> Styler:
    """ 自訂的報告表格基礎樣式 (Pandas CSS) """
    return (styler
        .hide(axis="index")
        .set_properties(**{
            'text-align': 'center',
            'border': '1px solid #e0e0e0',
            'padding': '8px'
        })
        .set_table_styles([
            {
                'selector': 'th',
                'props': 'background-color: #f4f4f4; color: #333333; font-weight: ↪
                ↪ bold; text-align: center; border-bottom: 2px solid #333333;'
            }
        ]))

```

```

)

def psnr(original: np.ndarray, reconstructed: np.ndarray, max_val: float = 255.0, axis: Optional[int] = None) -> Union[float, np.ndarray]:
    """ 計算 PSNR (Peak Signal-to-Noise Ratio) """
    orig = np.asarray(original, dtype=np.float64)
    recon = np.asarray(reconstructed, dtype=np.float64)
    mse = np.mean((orig - recon) ** 2, axis=axis)
    with np.errstate(divide='ignore'):
        result = 20 * np.log10(max_val / np.sqrt(mse))
    if np.ndim(result) == 0:
        return float('inf') if float(mse) < 1e-12 else float(result)
    return np.where(mse < 1e-12, float('inf'), result)

def ssim_metric(
    original: np.ndarray,
    reconstructed: np.ndarray,
    axis: Optional[int] = None,
    img_shape: Optional[tuple[int, int]] = None,
    max_val: float = 255.0,
) -> Union[float, np.ndarray]:
    """ 計算 SSIM (Structural Similarity Index) """
    if axis is not None and img_shape is not None:
        return np.array([
            skim_ssim(
                original[i].reshape(img_shape),
                reconstructed[i].reshape(img_shape),
                data_range=max_val,
            )
            for i in range(original.shape[0])
        ])
    return skim_ssim(original, reconstructed, data_range=max_val)

def svd_reconstruct(U: np.ndarray, s: np.ndarray, Vt: np.ndarray, q: int, mean_vec: Optional[np.ndarray] = None) -> np.ndarray:
    """ 通用截斷 SVD rank-q 重建 (使用廣播機制優化效能) """
    A_q = (U[:, :q] * s[:q]) @ Vt[:, :q, :]
    return A_q + mean_vec if mean_vec is not None else A_q

def img_finalize(img: np.ndarray) -> np.ndarray:
    """ 截斷像素值至 [0, 255] 並轉為 float64 """
    return np.clip(img, 0, 255).astype(np.float64)

def get_compression_ratio(m: int, n: int, q: int, patch_size: Optional[int] = None) -> float:
    """ 計算 SVD 或 Patch SVD 的壓縮比 """
    if patch_size is None:

```

```

        stored = q * (m + n + 1)
    else:
        n_patches = (m // patch_size) * (n // patch_size)
        stored = q * (n_patches + patch_size ** 2 + 1) + patch_size ** 2
    return (m * n) / stored

```

0.0.1 1-0. 影像載入與前處理

動機：我們需要一張具有豐富紋理的測試影像。使用 `scipy.datasets.face()` (浣熊影像) 轉為灰階後，`resize` 至 256×256 以在計算速度與影像品質之間取得平衡。

影像矩陣 $A \in \mathbb{R}^{m \times n}$ ，每個元素代表像素灰階值 $[0, 255]$ 。後續所有 SVD 與 PCA 操作均基於此矩陣進行。

本節目標：確認影像成功載入並顯示，記錄矩陣尺寸以供後續壓縮比計算使用。

```

[29]: # 載入 raccoon 影像並轉為灰階
img_color = scipy.datasets.face() # shape: (768, 1024, 3)
A_raw = (0.2989 * img_color[:, :, 0] + 0.5870 * img_color[:, :, 1] + 0.1140 *
    ↪img_color[:, :, 2]).astype(np.float64) # 灰階化 (ITU-R BT.601 luminance 加權)

# Resize 到 256×256 (避免 SVD 計算過慢)
zoom_factor = (256 / A_raw.shape[0], 256 / A_raw.shape[1])
A = zoom(A_raw, zoom_factor)
A = np.clip(A, a_min=0, a_max=255).astype(np.float64)
m, n = A.shape
print(f"原始影像尺寸: {A_raw.shape[0]} × {A_raw.shape[1]}")
print(f"縮放後影像尺寸: {m} × {n}")
print(f"像素值範圍: [{A.min():.1f}, {A.max():.1f}]")

fig, axes = plt.subplots(1, 2, figsize=(11, 4))
axes[0].imshow(A_raw, cmap='gray', vmin=0, vmax=255)
axes[0].set_title(f'原始影像 ({A_raw.shape[0]}×{A_raw.shape[1]}) ')
axes[0].axis('off')
axes[1].imshow(A, cmap='gray', vmin=0, vmax=255)
axes[1].set_title(f'縮放後影像 ({m}×{n}) ')
axes[1].axis('off')
plt.tight_layout()
plt.show()

```

原始影像尺寸：768 × 1024

縮放後影像尺寸：256 × 256

像素值範圍：[0.7, 250.6]

原始影像 (768×1024)



縮放後影像 (256×256)



0.0.2 1-1. 奇異值能量分布 (壓縮動機分析)

動機：在進行壓縮之前，我們必須先確認「壓縮是可行的」。

本節 (1-1 至 1-3) 是對**未中心化**的原始影像矩陣 A 直接進行 SVD。在這種情況下，第一個奇異值 σ_1 通常會單獨捕捉影像的 **DC 分量 (均值亮度)**，導致能量分布在 $q = 1$ 時顯得異常集中 (常達 80% 以上)。這在影像壓縮中是正常的，因為 SVD 的第一組基底即代表了影像的最基本色調。

影像矩陣 A 的 SVD 分解為：

$$A = U\Sigma V^T = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T$$

其中 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r \geq 0$ 。

能量集中性：若矩陣的「能量」(定義為 $\|A\|_F^2 = \sum_i \sigma_i^2$) 集中在前幾個奇異值，則用少量成分即可保留大部分資訊：

$$\text{Cumulative Energy Ratio}(q) = \frac{\sum_{i=1}^q \sigma_i^2}{\sum_{i=1}^r \sigma_i^2}$$

原始 SVD 壓縮比公式：保留 q 個成分需儲存 U 前 q 行 ($m \times q$)、奇異值 (q)、 V^T 前 q 行 ($q \times n$)。總儲存量為 $mq + nq + q = q(m + n + 1)$ ，其中 mq 對應 U ， nq 對應 V^T ， q 對應 Σ 。壓縮比為： $r = \frac{m \times n}{q \times (m + n + 1)}$

本節目標：用奇異值能量分布的數據說明「為什麼影像壓縮是可行的」，量化各能量門檻所需的 q 值。

```
[30]: # 對原始影像矩陣 (未中心化) 做完整 SVD
      U, s, Vt = np.linalg.svd(A, full_matrices=False)
      # U: (256, 256), s: (256,), Vt: (256, 256)
```

```

# 計算累積能量比例
energy = s ** 2
total_energy = np.sum(energy)
energy_ratio = np.cumsum(energy) / total_energy

# 找到達到各門檻所需的 q 值
thresholds = [0.80, 0.90, 0.95, 0.99]
q_thresholds = {}
for t in thresholds:
    q_thresholds[t] = int(np.searchsorted(energy_ratio, t)) + 1

# 畫三張並排圖
fig, axes = plt.subplots(1, 3, figsize=(15, 4))

# (a) 奇異值折線圖 (log scale)
axes[0].semilogy(s, 'b-', linewidth=1)
axes[0].set_xlabel('奇異值索引')
axes[0].set_ylabel('奇異值 (log scale) ')
axes[0].set_title('(a) 奇異值分布')
axes[0].grid(True, alpha=0.3)

# (b) 累積能量比例曲線
axes[1].plot(np.arange(1, len(energy_ratio)+1), energy_ratio, 'g-', linewidth=1.5)
for t in thresholds:
    axes[1].axhline(y=t, color='r', linestyle=':', alpha=0.5)
axes[1].set_xlabel('成分數 q')
axes[1].set_ylabel('累積能量比例')
axes[1].set_title('(b) 累積能量比例曲線')
axes[1].grid(True, alpha=0.3)

# (c) 標註門檻點 (前 100 個成分)
max_show = 100
axes[2].plot(np.arange(1, max_show+1), energy_ratio[:max_show], 'g-', linewidth=1.5)
colors_t = ['blue', 'orange', 'red', 'purple']
for (t, k), c in zip(q_thresholds.items(), colors_t):
    kk = min(k, max_show)
    axes[2].axvline(x=kk, color=c, linestyle='--', alpha=0.7)
    axes[2].axhline(y=t, color=c, linestyle=':', alpha=0.5)
    axes[2].plot(kk, energy_ratio[kk-1], 'o', color=c, markersize=8,
                  label=f'{int(t*100)}%: q={k}')
axes[2].set_xlabel('成分數 q')
axes[2].set_ylabel('累積能量比例')
axes[2].set_title(f'(c) 門檻標註 (前 {max_show} 個) ')
axes[2].legend(fontsize=8)
axes[2].grid(True, alpha=0.3)


```

```

plt.suptitle('影像矩陣奇異值能量分析', fontsize=14, fontweight='bold')
plt.tight_layout()
plt.show()

# 摘要表格
data_7 = []
for t in thresholds:
    k = q_thresholds[t]
    ratio = (m * n) / (k * (m + n + 1))
    data_7.append({
        '門檻': f"{int(t*100)}%",
        'q (所需成分)': k,
        '累積能量 %': t,
        '壓縮比': ratio
    })
df_7 = pd.DataFrame(data_7)
styled_df_7 = (df_7.style.pipe(apply_report_theme)
    .format({'累積能量 %': '{:.1%}', '壓縮比': '{:.1f}x'})
    .set_caption(f"奇異值能量摘要 (影像尺寸: {m}×{n}, 奇異值總數: {len(s)})")
)
display(styled_df_7)

```



<pandas.io.formats.style.Styler at 0x116fe4da0>

觀察：

從 (a) 圖可以看到，奇異值呈現快速衰減的模式——前幾個奇異值遠大於其餘，這是影像矩陣低秩近似可行的關鍵依據。

從 (b)(c) 圖與摘要表格可知：- 僅需保留少量成分（如 $q=3$ ）即可涵蓋 90% 以上的能量 - 對應的壓縮比相當高，代表即使大幅壓縮，影像品質也不會嚴重下降

數學意義：這說明影像矩陣具有低秩結構 (low-rank structure)，其資訊可以被少數奇異成分良好近似。這是 Eckart-Young 定理 (1-3 節) 的基礎：截斷 SVD 提供最佳低秩近似。

0.0.3 1-2. SVD rank-q 重建

動機：定義截斷 SVD 重建的數學操作，並量化不同 q 值下的視覺品質。

截斷 SVD：保留前 q 個奇異成分的最佳 rank- q 近似：

$$A_q = U_q \Sigma_q V_q^T = \sum_{i=1}^q \sigma_i \mathbf{u}_i \mathbf{v}_i^T$$

PSNR（峰值信噪比）：衡量重建影像品質的標準指標：

$$\text{PSNR} = 20 \log_{10} \left(\frac{255}{\sqrt{\text{MSE}}} \right), \quad \text{MSE} = \frac{1}{mn} \|A - A_q\|_F^2$$

PSNR > 30 dB 通常被認為視覺品質良好；> 40 dB 則幾乎無法與原圖區分。

驗證目標：展示 q 從 1 到 100 的重建結果，量化壓縮比與影像品質的取舍關係。

```
[31]: # 測試不同 q 值
q_values = [1, 5, 10, 20, 50, 100]

fig, axes = plt.subplots(2, 3, figsize=(15, 10))
axes = axes.flatten()

data_10 = []
for idx, q in enumerate(q_values):
    A_q = svd_reconstruct(U, s, Vt, q)
    A_q_clipped = img_finalize(A_q)
    ratio = (m * n) / (q * (m + n + 1))
    p_val = psnr(A, A_q_clipped)
    s_val = ssim_metric(A, A_q_clipped)
    stored = q * (m + n + 1)

    axes[idx].imshow(A_q_clipped, cmap='gray', vmin=0, vmax=255)
    axes[idx].set_title(f'q={q}, r={ratio:.1f}x\nPSNR={p_val:.1f}dB, SSIM={s_val:.3f}',
                        fontsize=9)
    axes[idx].axis('off')
    data_10.append({
        'q': q,
        '壓縮比': ratio,
        'PSNR (dB)': p_val,
        'SSIM': s_val,
        '儲存數值數': stored
    })

df_10 = pd.DataFrame(data_10)
styled_df_10 = (df_10.style.pipe(apply_report_theme))
```


```

        .format({'壓縮比': '{:.1f}x', 'PSNR (dB)': '{:.2f}', 'SSIM': '{:.3f}', '儲存
        數值數': '{:,}'})
        .background_gradient(subset=['PSNR (dB)'], cmap='Blues')
        .set_caption(f"SVD rank-q 重建品質摘要 (原始儲存量: {m*n:,} 像素)")
    )
display(styled_df_10)

plt.suptitle('SVD rank-q 影像重建', fontsize=14, fontweight='bold')
plt.tight_layout()
plt.show()

```

<pandas.io.formats.style.Styler at 0x11762d490>



觀察：

- $q=1$ ：PSNR 極低，影像僅呈現最主要的全域亮度梯度，細節完全消失。
- $q=5\sim 10$ ：可辨認出影像的輪廓，但仍有明顯的壓縮偽影（artifact）。
- $q=20$ ：對應約 6x 壓縮比，影像已具備不錯的視覺品質（PSNR 通常 $> 25\text{dB}$ ）。
- $q=50$ ：PSNR 通常超過 30dB，肉眼難以察覺與原圖的差異。
- $q=100$ ：壓縮比仍有約 1.3x，PSNR 很高，實際上達到幾乎無損壓縮。

數學意義：PSNR 的快速提升反映了奇異值能量的集中性——前少數成分已編碼了影像的主要結構，後續成分僅貢獻高頻細節（紋理、邊緣），且每個額外成分的邊際貢獻逐漸遞減。

0.0.4 1-3. Eckart-Young 定理數值驗證

定理陳述 (Eckart-Young-Mirsky, 1936) :

設 A 的 SVD 為 $A = U\Sigma V^T$ ，截斷 SVD $A_q = U_q \Sigma_q V_q^T$ 。則對於所有 rank 至多為 q 的矩陣 B ，有：

$$\|A - A_q\|_F \leq \|A - B\|_F$$

且誤差可由奇異值精確計算：

$$\|A - A_q\|_F = \sqrt{\sum_{i=q+1}^r \sigma_i^2}$$

意義：截斷 SVD 是 Frobenius norm 意義下的最佳低秩近似，不存在任何 rank- q 矩陣能比 A_q 更接近 A 。

與 PSNR 的直接關聯：Section 1-2 使用 PSNR 作為重建品質指標，而 PSNR 與 Frobenius norm 具有以下關係：

$$\text{PSNR} = 20 \log_{10} \left(\frac{255}{\sqrt{\text{MSE}}} \right), \quad \text{MSE} = \frac{\|A - A_q\|_F^2}{m \times n}$$

因此 **PSNR 最大化** $\Leftrightarrow$ **MSE 最小化** $\Leftrightarrow$ **Frobenius norm 最小化**。Eckart-Young 定理保證截斷 SVD 使 $\|A - A_q\|_F$ 最小，故同時也是 PSNR 意義下的最優 rank- q 近似。Section 1-2 的 PSNR 曲線因此具有理論支撐：不存在任何其他 rank- q 壓縮方式能給出比截斷 SVD 更高的 PSNR。

驗證目標：數值驗證上式——實驗計算的 $\|A - A_q\|_F$ 應與理論值 $\sqrt{\sum_{i>q} \sigma_i^2}$ 完全吻合（差值在機器精度附近）。

```
[32]: q_range = np.arange(1, min(100, len(s)))

# 理論值：利用奇異值平方和計算 sqrt( $\sum_{i>q} \sigma_i^2$ )
s_sq = s ** 2
err_theoretical = np.sqrt(np.sum(s_sq) - np.cumsum(s_sq))[q_range - 1]

# 實驗值：逐個  $q$  重建  $A_q$ ，再直接計算  $\|A - A_q\|_F$ 
err_empirical = np.array([
    np.linalg.norm(A - svd_reconstruct(U, s, Vt, q), 'fro')
    for q in q_range
])

fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# 左圖：兩條線應完全重疊
axes[0].plot(q_range, err_empirical, 'b-', linewidth=2.5, label='實驗值  $\|A - A_q\|_F$ ')
```

```


axes[0].plot(q_range, err_theoretical, 'r--', linewidth=1.5, label='理論值  $\sqrt{\sum_{i>q} \sigma_i^2}$ ')
axes[0].set_xlabel('rank q')
axes[0].set_ylabel('Frobenius 誤差')
axes[0].set_title('Eckart-Young 定理：實驗值 vs 理論值')
axes[0].legend()
axes[0].grid(True, alpha=0.3)

# 右圖：差值（應在機器精度附近）
diff = np.abs(err_empirical - err_theoretical)
axes[1].semilogy(q_range, diff + 1e-20, 'g-', linewidth=1.5)
axes[1].axhline(y=np.finfo(float).eps * err_empirical.max(), color='r',
                linestyle='--', label=f'機器精度參考線')
axes[1].set_xlabel('rank q')
axes[1].set_ylabel('| 實驗值 - 理論值 | (log scale)')
axes[1].set_title('絕對差值')
axes[1].legend()
axes[1].grid(True, alpha=0.3)

plt.suptitle('Eckart-Young 定理數值驗證', fontsize=14, fontweight='bold')
plt.tight_layout()
plt.show()

max_diff = np.max(diff)
eps = np.finfo(float).eps
print(f"實驗值與理論值最大差值：{max_diff:.2e}")
print(f"機器精度 (float64 eps):{eps:.2e}")
print(f"相對差值 (max_diff / max_err):{max_diff / err_empirical.max():.2e}")

```



實驗值與理論值最大差值：1.78e-10
 機器精度 (float64 eps):2.22e-16
 相對差值 (max_diff / max_err):1.45e-14

驗證結論：

右圖顯示實驗值與理論值的差值約在 10^{-10} 至 10^{-12} 量級，符合 float64 數值計算的機器精度 ($\epsilon \approx 2.2 \times 10^{-16}$)，考慮矩陣乘法累積誤差後仍在合理範圍內。

左圖兩條線完全重疊，定理得到完美的數值驗證。

這也定量說明了截斷 SVD 是最優低秩近似：任何其他 rank- q 矩陣的 Frobenius 誤差都不可能低於 $\sqrt{\sum_{i>q} \sigma_i^2}$ 。

0.0.5 1-3b. Gavish-Donoho 最佳奇異值截斷門檻

動機：前面的 rank- q 選取方式是人工指定 q 值。Gavish & Donoho (2014) 在 *The Optimal Hard Threshold for Singular Values is $4/\sqrt{3}$* 一文中，針對含高斯雜訊的矩陣推導了**理論最佳截斷門檻** τ^* ：

$$\tau^* = \omega(\beta) \cdot \hat{\sigma} \cdot \sqrt{n}$$

其中 $\beta = m/n$ ($m \leq n$)， $\omega(\beta)$ 為與長寬比相關的係數， $\hat{\sigma}$ 為雜訊標準差估計值（使用奇異值中位數除以 μ_β ）。

前提假設說明：GD 定理的推導基於「真實信號矩陣 S 疊加 i.i.d. 高斯白雜訊 N 」的模型： $A = S + N$ ，其中 $N_{ij} \sim \mathcal{N}(0, \sigma^2)$ 。本節使用的浣熊影像**並非**此模型下的噪聲觀測值，因此 GD 截斷在此處不具備統計最優性保證，僅作為方法對照，觀察其在自然影像上的行為。

本節目標：

1. 實作 Gavish-Donoho 門檻，自動決定最佳 q
2. 與「累積能量法」（如保留 90%/99% 奇異值能量）進行比較
3. 探討兩種方法在不同信噪比假設下的適用情境

```
[33]: def gavish_donoho_threshold(s, m, n, sigma=None):
    """
    計算 Gavish-Donoho (2014) 最佳奇異值截斷門檻。

    Parameters
    -----
    s      : ndarray 全集奇異值 (降序)
    m, n   : int      矩陣維度 (m <= n)
    sigma  : float / None
              已知雜訊標準差。若為 None，則使用 Median Absolute Deviation
              估計：sigma_hat = median(s) / (sqrt(n) * mu_beta)

    Returns
    -----
    tau    : float 截斷門檻 (絕對值)
    q_gd   : int    保留的奇異值數量 (s[i] >= tau 的個數)
    sigma_hat : float 所用雜訊估計值
    """
    beta = m / n # 長寬比 (<= 1)

    # ( ) : 未知 情況下的最佳門檻係數 (Gavish & Donoho 2014, Eq. 11)
```



```

# 對  $\beta=1$  (方形矩陣), (1) 2.858
w = (0.56 * beta**3 - 0.95 * beta**2 + 1.82 * beta + 1.43)

# lambda_beta: 奇異值規模化常數, 用於將  $\text{median}(s)/\sqrt{n}$  轉換為  $\hat{\sigma}$ 
# 此公式來自 Gavish & Donoho (2014) 的實作, 對  $\beta=1$  時值為  $4/\sqrt{3} \approx 2.309$ ,
# 即已知  $\beta$  時的最優截斷係數  $\lambda_{\text{known}}()$ 。
# 注意: 此值並非 Marchenko-Pastur 奇異值分佈的中位數
# (對  $\beta=1$ , MP 分佈支撐為  $[0, 2]$ , 中位數  $< 2$ ; 此公式輸出 2.309 超出此範圍)。
# 此公式在各  $\beta$  下提供合理的規模化估計, 但標籤不應稱為「中位數」。
lambda_beta = np.sqrt(2 * (beta + 1) + (8 * beta) / (beta + 1 + np.
↪sqrt(beta**2 + 14 * beta + 1)))

if sigma is None:
    # 使用奇異值中位數估計雜訊強度:  $\sigma_{\text{hat}} = \text{median}(s) / (\sqrt{n} \times \lambda_{\text{beta}})$ 
↪lambda_beta)
    sigma_hat = np.median(s) / (np.sqrt(n) * lambda_beta)
else:
    sigma_hat = sigma

tau = w * sigma_hat * np.sqrt(n)
q_gd = int(np.sum(s >= tau))
return tau, q_gd, sigma_hat

# 對浣熊影像執行 Gavish-Donoho
m_img, n_img = A.shape # 應為 256 x 256
tau_gd, q_gd, sigma_est = gavish_donoho_threshold(s, m_img, n_img)

print(f"影像尺寸: {m_img} x {n_img}")
print(f"估計雜訊 sigma_hat = {sigma_est:.4f}")
print(f"Gavish-Donoho 門檻 tau_star = {tau_gd:.2f}")
print(f"自動選取 q_GD = {q_gd} (共 {len(s)} 個奇異值) ")

# 與累積能量法比較
# 重用 Section 1-1 已計算的 energy_ratio (相同定義)
q_90 = int(np.searchsorted(energy_ratio, 0.90)) + 1
q_99 = int(np.searchsorted(energy_ratio, 0.99)) + 1

print(f"\n累積能量 90% → q = {q_90}")
print(f"累積能量 99% → q = {q_99}")
print(f"Gavish-Donoho → q = {q_gd}")

# 視覺比較: 三種方法的重建結果
methods = {
    f'GD 自動 (q={q_gd})': q_gd,
    f'能量 90% (q={q_90})': q_90,
    f'能量 99% (q={q_99})': q_99,

```

```

}

fig, axes = plt.subplots(1, len(methods) + 1, figsize=(4 * (len(methods) + 1), 4))

axes[0].imshow(A, cmap='gray', vmin=0, vmax=255)
axes[0].set_title('原始影像', fontsize=10)
axes[0].axis('off')

for i, (label, q_val) in enumerate(methods.items()):
    A_rec = img_finalize(svd_reconstruct(U, s, Vt, q_val))
    p_val = psnr(A, A_rec)
    ratio = get_compression_ratio(m_img, n_img, q_val)
    axes[i + 1].imshow(A_rec, cmap='gray', vmin=0, vmax=255)
    axes[i + 1].set_title(f'{label}\nPSNR={p_val:.1f}dB, 壓縮比={ratio:.1f}x',
        fontsize=9)
    axes[i + 1].axis('off')

plt.suptitle('q 選取方法比較：Gavish-Donoho vs 累積能量法', fontsize=14,
    fontweight='bold')
plt.tight_layout()
plt.show()

# 奇異值分布圖：標示各方法的截斷位置
fig, ax = plt.subplots(figsize=(10, 4))
ax.semilogy(np.arange(1, len(s) + 1), s, color='steelblue', linewidth=1.5,
    label='奇異值')
ax.axvline(q_gd, color='red', linestyle='--', linewidth=1.5, label=f'GD 截斷
    (q={q_gd})')
ax.axvline(q_90, color='green', linestyle=':', linewidth=1.5, label=f'90% 能
    量 (q={q_90})')
ax.axvline(q_99, color='orange', linestyle='-.', linewidth=1.5, label=f'99% 能
    量 (q={q_99})')
ax.axhline(tau_gd, color='red', linestyle='--', linewidth=1, alpha=0.5,
    label=f'tau_star={tau_gd:.1f}')
ax.set_xlabel('奇異值排名 i')
ax.set_ylabel('奇異值 sigma_i (對數軸)')
ax.set_title('奇異值分布與各方法截斷位置', fontweight='bold')
ax.legend(fontsize=9)
ax.grid(True, alpha=0.3)
plt.tight_layout()
plt.show()

```


影像尺寸：256 × 256

估計雜訊 $\sigma_{\text{hat}} = 7.0363$

Gavish-Donoho 門檻 $\tau_{\text{star}} = 321.98$

自動選取 $q_{\text{GD}} = 107$ (共 256 個奇異值)

累積能量 90% $\rightarrow q = 3$
 累積能量 99% $\rightarrow q = 68$
 Gavish-Donoho $\rightarrow q = 107$



Gavish-Donoho 分析結論：

- **GD 自動門檻：**假設矩陣帶有加性高斯白雜訊 (AWGN)，自動選取在統計意義上最佳的截斷位置。對「含雜訊」的影像重建特別適用。
- **累積能量 90%：**通常選取較少的成分，壓縮比高但可能損失更多細節。
- **累積能量 99%：**保留更多成分，重建品質高但壓縮率低。
- **適用情境：**GD 適合「去雜訊」場景（保留信號、截斷雜訊主導的奇異值）；累積能量法適合「固定壓縮比」場景；人臉辨識 (Section 3) 中建議以辨識準確率為最終依據。

本節的侷限性：浣熊影像不符合 GD 的 AWGN 模型假設。在此情況下：

1. **$\hat{\sigma}$ 估計偏高：**GD 使用奇異值中位數估計雜訊強度；對自然影像而言，中位數附近的奇異值對應的是影像的中頻紋理，並非真正的雜訊，導致 $\hat{\sigma}$ 被高估，進而使截斷門檻 τ^* 偏高、保留的 q 值偏少。
2. **截斷結果偏保守：**實驗中 GD 選出的 q_{GD} 通常少於「能量 90%」法，在自然影像上意味著丟失較多中高頻細節，而非去除雜訊。
3. **正確的使用情境：**若需對含真實雜訊的影像（如感測器噪聲、量化誤差）進行去噪，GD 門檻才能發揮統計最優的截斷效果。

0.0.6 1-4. PCA 等價性驗證

本節與前三節 (1-1 至 1-3) 在矩陣操作上有一個本質上的不同點：前三節是對原始影像矩陣 A 做 SVD 以進行「重建壓縮」，目的是保留最多的能量；而本節旨在驗證 PCA 的等價性。PCA 與 SVD 的等價性 僅在對同一個「中心化矩陣做 SVD 時成立。因此，本節的操作對象切換為中心化後的 $\tilde{A} = A - \bar{a}\mathbf{1}^T$ 。

差異點：中心化會移除影像的 DC 均值亮度分量，因此 $\tilde{A}$ 的第一奇異值 σ_1 不再像 1-1 節那樣捕捉全域亮度，而是捕捉「最強的像素變異方向」。這會導致奇異值分布相較於未中心化 SVD 顯得較為平緩。

推導：

設 $\tilde{A} = A - \mathbf{1}\bar{a}^T$ ($\bar{a}^T$ 為各像素位置的樣本均值，即對 axis=0 做中心化)。

PCA 的 Gram matrix 為 $C = \tilde{A}^T \tilde{A}$ (未除以 $m-1$ ，等同於樣本協方差矩陣的 $(m-1)$ 倍)。

若 $\tilde{A} = U\Sigma V^T$ ，則：

$$C = \tilde{A}^T \tilde{A} = (V\Sigma U^T)(U\Sigma V^T) = V\Sigma^2 V^T$$

因此 C 的特徵向量 = $\tilde{A}$ 的右奇異向量 V ；特徵值 $\lambda_i = \sigma_i^2$ 。

若使用協方差矩陣 $\frac{1}{m-1}\tilde{A}^T \tilde{A}$ ，則 $\lambda_i = \sigma_i^2/(m-1)$ 。

驗證目標：

1. 特徵值： λ_i (eigh) $\approx \sigma_i^2$ (SVD)
2. 特徵向量：PCA 的主方向 $\approx$ SVD 的右奇異向量 (符號對齊後)
3. 重建誤差：PCA 重建 $\approx$ SVD 重建 (差值 $< 10^{-8}$)

```
[34]: # Step 1: 中心化 (減去每個像素位置的樣本均值，即 column mean)
A_centered = A - A.mean(axis=0, keepdims=True) # shape: (m, n)

# Step 2: 計算 Gram matrix (n×n)
ATA = A_centered.T @ A_centered # shape: (n, n) = (256, 256)

# Step 3: eig (適用對稱矩陣，結果從小到大排序)
eigenvalues, V_pca = np.linalg.eigh(ATA)

# Step 4: 反轉排序 (從大到小)
idx = np.argsort(eigenvalues)[::-1]
eigenvalues = eigenvalues[idx]
V_pca = V_pca[:, idx] # 每列是一個主成分方向，shape: (n, n)

# Step 5: 對中心化矩陣做完整 SVD
U_svd, s_svd, Vt_svd = np.linalg.svd(A_centered, full_matrices=False)
V_svd = Vt_svd.T # 右奇異向量，shape: (n, min(m,n))

# Step 6: 理論關係 ATA = V Σ² Vᵀ，故特徵值 = σ²
eigenvalues_from_svd = s_svd ** 2
```

```

r_common = min(len(eigenvalues), len(eigenvalues_from_svd))


# 驗證 (a)：特徵值比較
fig, axes = plt.subplots(1, 2, figsize=(12, 5))
axes[0].scatter(eigenvalues_from_svd[:r_common], eigenvalues[:r_common],
                alpha=0.5, s=15, c='steelblue')
lim_min = min(eigenvalues_from_svd[:r_common].min(), eigenvalues[:r_common].
    ↪min())
lim_max = max(eigenvalues_from_svd[:r_common].max(), eigenvalues[:r_common].
    ↪max())
axes[0].plot([lim_min, lim_max], [lim_min, lim_max], 'r--', linewidth=1.5,
    ↪label='y = x')
axes[0].set_xlabel('SVD :  $\sigma_i^2$ ')
axes[0].set_ylabel('PCA (eigh) :  $\lambda_i$ ')
axes[0].set_title('特徵值驗證 :  $\lambda_i^2$  vs  $\lambda_i$  (應落在 y=x 線上)')
axes[0].legend()
axes[0].grid(True, alpha=0.3)

ev_diff = np.abs(eigenvalues[:r_common] - eigenvalues_from_svd[:r_common])
axes[1].semilogy(ev_diff + 1e-20, 'g-', linewidth=1.5)
axes[1].set_xlabel('成分索引')
axes[1].set_ylabel(''| $\lambda_i - \lambda_i^2$ | (log scale)')
axes[1].set_title('特徵值差值 (應在數值誤差範圍內)')
axes[1].grid(True, alpha=0.3)

plt.suptitle('PCA 等價性驗證 (a)：特徵值比較', fontsize=14, fontweight='bold')
plt.tight_layout()
plt.show()
print(f"特徵值最大絕對差值 ( $\lambda_i$  vs  $\lambda_i^2$ ): {np.max(ev_diff):.2e}")

```

PCA 等價性驗證 (a)：特徵值比較



特徵值最大絕對差值 (λ_i vs λ_i^2) : 5.22e-08

```

[35]: # 驗證 (b): 符號對齊 (eigenvectors 符號不唯一)
def align_signs(V_ref, V_target):
    """
    對齊兩組特徵向量的符號，確保可比較。
    使用兩列的內積符號進行對齊，比僅比較第一個元素更為穩健。
    """
    V_target = V_target.copy()
    for i in range(min(V_ref.shape[1], V_target.shape[1])):
        # 若內積為負值，則翻轉符號
        if np.dot(V_ref[:, i], V_target[:, i]) < 0:
            V_target[:, i] *= -1
    return V_target

V_svd_aligned = align_signs(V_pca, V_svd.copy())

# 驗證 (c): q=20 重建誤差
q = 20
mean_vec = A.mean(axis=0, keepdims=True) # shape: (1, n), 用於還原中心化

# PCA 重建: 投影到主成分空間後還原
V_q = V_pca[:, :q] # shape: (n, q)
scores = A_centered @ V_q # shape: (m, q), 投影係數
A_pca_reconstructed = scores @ V_q.T + mean_vec # 加回均值

# SVD 重建 (對中心化矩陣) 加回均值
A_svd_reconstructed = svd_reconstruct(U_svd, s_svd, Vt_svd, q,
    ↪mean_vec=mean_vec)

diff_recon = np.linalg.norm(A_pca_reconstructed - A_svd_reconstructed, 'fro')
print(f"q = {q}")
print(f"PCA 重建與 SVD 重建的 Frobenius norm 差值: {diff_recon:.2e} (應 < 1e-8)")
print(f"驗證通過: {diff_recon < 1e-8}")

# 驗證 (d): 視覺比較
fig, axes = plt.subplots(1, 3, figsize=(15, 5))
A_display = img_finalize(A)
A_pca_clipped = img_finalize(A_pca_reconstructed)
A_svd_clipped = img_finalize(A_svd_reconstructed)

axes[0].imshow(A_display, cmap='gray', vmin=0, vmax=255)
axes[0].set_title('原始影像', fontsize=11)
axes[0].axis('off')

p_pca = psnr(A, A_pca_clipped)
axes[1].imshow(A_pca_clipped, cmap='gray', vmin=0, vmax=255)

```

```

axes[1].set_title(f'PCA 重建 (q={q}) \nPSNR={p_pca:.2f}dB', fontsize=10)
axes[1].axis('off')

p_svd = psnr(A, A_svd_clipped)
axes[2].imshow(A_svd_clipped, cmap='gray', vmin=0, vmax=255)
axes[2].set_title(f'SVD 重建 (中心化, q={q}) \nPSNR={p_svd:.2f}dB', fontsize=10)
axes[2].axis('off')

plt.suptitle(f'PCA vs SVD 重建對比 (q={q})', fontsize=12, fontweight='bold')
plt.tight_layout()
plt.show()

```

q = 20

PCA 重建與 SVD 重建的 Frobenius norm 差值：3.38e-11 （應 < 1e-8）

驗證通過：True



等價性驗證結論：

1. **特徵值**：PCA (eigh) 的特徵值 λ_i 與 SVD 的 σ_i^2 差值約在 10^{-8} 量級，符合數值誤差。
2. **重建差值**：PCA 重建與 SVD 重建的 Frobenius norm 差值 < 10^{-8} ，等價性得到嚴格數值驗證。
3. **視覺結果**：兩張重建影像 PSNR 完全相同，肉眼無法區分。

關鍵洞察：PCA 與 SVD 等價性的前提是對同一個中心化矩陣操作。若對原始影像（未中心化）做 SVD，與 PCA 的結果會有顯著差異——這解釋了為何本節必須先做中心化再比較。

0.0.7 2-1. Patching 動機說明

全域 SVD 的限制：直接對整張 $m \times n$ 影像做 SVD，奇異向量捕捉的是**全域性的低頻結構**（如整體亮度分布、長程漸變）。這在高壓縮比下可能遺漏重要的局部紋理（如毛髮、邊緣）。

Patch SVD 的核心想法：

1. **空間局部化**：將影像切成 $p \times p$ 的不重疊小塊（共 N_p 個），使奇異向量能捕捉局部紋理的基底模式。

2. **Patch 中心化 (Centering)**：在進行 SVD 之前，我們先計算每個 $p \times p$ 小塊的平均亮度 (DC 分量) 並將其扣除。這項操作的動機有二：
 - **與 PCA 一致性**：確保 SVD 捕捉的是局部像素的變異方向，而非由平均亮度主導的能量。這與 Section 1-4 的討論一致。
 - **特徵提取效率**：移除 DC 分量後，奇異向量能更專注於描述邊緣、紋理等中高頻資訊，這通常能使奇異值能量分佈在局部尺度上更為集中。

儲存開銷說明：由於每個 patch 都經過中心化，重建時必須額外儲存該 patch 的平均向量（長度 p^2 ）。這就是為何 Patch SVD 的壓縮比公式中必須包含 p^2 補償項的原因。

驗證目標：在固定壓縮比的前提下，比較不同 patch size 的重建品質 (PSNR)，找出各壓縮比下的最佳 patch size。

0.0.8 2-2. Patch 函數實作

```
[36]: import numpy as np

def extract_patches(img, patch_size):
    """
    將影像切成不重疊的 patch，展平後堆成矩陣。
    注意：此函數僅執行『切割與展平』，『中心化』步驟應在分解前另外執行。

    數學：將  $m \times n$  影像分割為  $(m/p) \times (n/p)$  個  $p \times p$  小塊，
    每塊展平為長度  $p^2$  的向量，堆疊成  $(N_p, p^2)$  矩陣。

    Parameters
    -----
    img : ndarray, shape (m, n)
    patch_size : int, patch 邊長 p (要求 m, n 都能被 p 整除)

    Returns
    -----
    patch_matrix : ndarray, shape (N_p, p*p)
        N_p = (m//p) * (n//p)
    meta : dict, 包含 original_shape, patches_per_row, patches_per_col
    """
    m, n = img.shape
    p = patch_size
    assert m % p == 0 and n % p == 0, (
        f"影像尺寸 {m}x{n} 必須能被 patch_size={p} 整除"
    )
    patches_per_row = m // p
    patches_per_col = n // p

    # reshape → (patches_per_row, p, patches_per_col, p)
    patches = img.reshape(patches_per_row, p, patches_per_col, p)
    # transpose → (patches_per_row, patches_per_col, p, p)
    patches = patches.transpose(0, 2, 1, 3)
```

```

# 展平每個 patch → (N_p, p²)
patch_matrix = patches.reshape(patches_per_row * patches_per_col, p * p)

meta = {
    'original_shape': img.shape,
    'patches_per_row': patches_per_row,
    'patches_per_col': patches_per_col
}
return patch_matrix, meta

def reconstruct_from_patches(patch_matrix, meta, patch_size):
    """
    將 patch 矩陣重建回影像 (extract_patches 的逆運算)。

    Parameters
    -----
    patch_matrix : ndarray, shape (N_p, p*p)
    meta : dict, 來自 extract_patches 的 meta
    patch_size : int

    Returns
    -----
    img_reconstructed : ndarray, shape (m, n)
    """
    p = patch_size
    m, n = meta['original_shape']
    patches_per_row = meta['patches_per_row']
    patches_per_col = meta['patches_per_col']

    patches = patch_matrix.reshape(patches_per_row, patches_per_col, p, p)
    patches = patches.transpose(0, 2, 1, 3) # → (patches_per_row, p, patches_per_col, p)
    img_reconstructed = patches.reshape(m, n)
    return img_reconstructed

```

0.0.9 2-3. Patch SVD 壓縮比公式

推導：設 patch 矩陣 $P \in \mathbb{R}^{N_p \times p^2}$ ，其中 $N_p = \frac{m}{p} \times \frac{n}{p}$ 。

截斷 SVD 保留 q 個成分後，需儲存：

- U 的前 q 列： $N_p \times q$ 個數值
- 奇異值： q 個數值
- V^T 的前 q 行： $q \times p^2$ 個數值

若 patch SVD 是對中心化後的 patch 矩陣進行分解，則重建時還必須額外儲存 patch 平均向量

(長度 p^2)。因此總儲存量為：

$$N_p q + p^2 q + q + p^2 = q(N_p + p^2 + 1) + p^2$$

其中 $N_p q$ 對應 U ， $p^2 q$ 對應 V^T ， q 對應 Σ ，最後的 p^2 對應 patch mean。

壓縮比：

$$r = \frac{m \times n}{q \times (N_p + p^2 + 1) + p^2}$$

注意：patch_size=1 時， $N_p = m \times n$ ， $p^2 = 1$ ，壓縮比公式退化為 $\frac{mn}{q(mn+2)} \approx \frac{1}{q}$ ，與對整張影像做 rank-1 近似的概念不同（因為每個「patch」只是一個像素點）。實際上，對一個 $N_p \times 1$ 的矩陣做 SVD 並不同於 k-means 類型的向量量化。k-means 涉及群聚分配（assignment）步驟，而對 $N_p \times 1$ 的矩陣做 SVD 僅是一個純量的分解，相當於對像素值進行排序與投影，與群聚無關。因此本實驗中 patch_size=1 退化為一種特殊情況，主要作為公式一致性的驗證與比較基準。

```
[37]: def patch_compression_ratio(m, n, patch_size, q):
```

```
    """
```

```
    計算 Patch SVD 的壓縮比。
```

```
    儲存量公式： $q \times (N_p + p^2 + 1) + p^2$ 
```

```
    其中額外的  $p^2$  來自 patch mean，因為本實驗先對 patch 矩陣做中心化。
```

```
    Parameters
```

```
    -----
```

```
    m, n : int 影像尺寸
```

```
    patch_size : int patch 邊長 p
```

```
    q : int 保留的 SVD 成分數
```

```
    Returns
```

```
    -----
```

```
    float 壓縮比（原始像素數 / 儲存數值數）
```

```
    """
```

```
    p = patch_size
```

```
    n_patches = (m // p) * (n // p)
```

```
    stored = q * (n_patches + p * p + 1) + p * p
```

```
    return (m * n) / stored
```

```
# 示範：展示不同 patch_size 下達到相同壓縮比所需的 q
```

```
demo_ratio = 10.0
```

```
data_26 = []
```

```
for p in [1, 4, 8, 16, 32]:
```

```
    if m % p != 0 or n % p != 0:
```

```
        continue
```

```
    n_patches = (m // p) * (n // p)
```

```
    # 找最大 q 使得壓縮比 >= demo_ratio
```

```
    max_q_possible = min(n_patches, p * p)
```

```
    best_q = 0
```

```

for q_try in range(1, max_q_possible + 1):
    if patch_compression_ratio(m, n, p, q_try) >= demo_ratio:
        best_q = q_try
    else:
        break
if best_q > 0:
    actual_r = patch_compression_ratio(m, n, p, best_q)
    data_26.append({
        'patch_size': f"{p}×{p}",
        'q': best_q,
        '實際壓縮比': actual_r,
        'N_p': n_patches,
        'p2': p*p
    })

df_26 = pd.DataFrame(data_26)
styled_df_26 = (df_26.style.pipe(apply_report_theme)
    .format({'實際壓縮比': '{:.2f}x'})
    .set_caption(f"目標壓縮比 {demo_ratio}x 所需的 q 值")
)
display(styled_df_26)

```

<pandas.io.formats.style.Styler at 0x118508e90>

0.0.10 2-4. 對照實驗設計

關鍵設計原則：固定壓縮比，比較不同 patch size 的重建品質 (PSNR)。對每個 (patch_size, target_ratio) 組合，找最大的 q 使得 $r(q) \geq \text{target_ratio}$ ，確保比較在相同資訊量（壓縮比）的條件下進行。

```

[38]: patch_sizes = [8, 16, 32, 64]
      target_ratios = [5, 10, 20, 50]

      results = {} # key: (patch_size, target_ratio) → dict
      patch_svd_cache = {} # 用於快取 SVD 結果，避免後續章節重複計算

      for p in patch_sizes:
          if m % p != 0 or n % p != 0:
              print(f"跳過 patch_size={p} (影像尺寸 {m}×{n} 不整除)")
              continue

          # 提取 patches 並中心化
          patch_mat, meta = extract_patches(A, p)
          patch_mean = patch_mat.mean(axis=0, keepdims=True) # shape: (1, p2)
          patch_centered = patch_mat - patch_mean

          # 對 patch 矩陣做 SVD
          U_p, s_p, Vt_p = np.linalg.svd(patch_centered, full_matrices=False)

```

```

# 將結果存入快取
patch_svd_cache[p] = {
    'U_p': U_p,
    's_p': s_p,
    'Vt_p': Vt_p,
    'patch_mean': patch_mean,
    'meta': meta
}

max_q = len(s_p)

for target_r in target_ratios:
    # 找最大 q 使得壓縮比 >= target_r
    best_q = 0
    for q_try in range(1, max_q + 1):
        r_try = patch_compression_ratio(m, n, p, q_try)
        if r_try >= target_r:
            best_q = q_try
        else:
            break

    if best_q > 0:
        q = best_q
        # rank-q 重建 patch (加回均值)
        patch_rec = (U_p[:, :q] * s_p[:q]) @ Vt_p[:, :q] + patch_mean
        img_rec = np.clip(reconstruct_from_patches(patch_rec, meta, p), 0, 1
↪255)

        actual_ratio = patch_compression_ratio(m, n, p, q)
        psnr_val = psnr(A, img_rec)

        results[(p, target_r)] = {
            'q': q,
            'actual_ratio': actual_ratio,
            'psnr': psnr_val,
            'img': img_rec
        }

# PSNR 表格
data_28_psnr = []
for p in patch_sizes:
    row_data = {'Patch size': f"{p}×{p}"}
    for r in target_ratios:
        if (p, r) in results:
            row_data[f"r {r}x"] = results[(p, r)]['psnr']
        else:

```

```

        row_data[f"r {r}x"] = None
    data_28_psnr.append(row_data)

df_28_psnr = pd.DataFrame(data_28_psnr)
styled_df_28_psnr = (df_28_psnr.style.pipe(apply_report_theme)
    .format(na_rep='N/A', precision=2)
    .highlight_max(axis=0, subset=[f"r {r}x" for r in target_ratios],
        props='background-color: #d4edda; color: #155724;
        ↪font-weight: bold;')
    .set_caption("Patch SVD 對照實驗：PSNR (dB)")
)
display(styled_df_28_psnr)

# 實際使用的 q 值表格
data_28_q = []
for p in patch_sizes:
    row_data = {'Patch size': f"{p}×{p}"}
    for r in target_ratios:
        if (p, r) in results:
            res = results[(p, r)]
            row_data[f"r {r}x"] = f"q={res['q']} ({res['actual_ratio']:.1f}x)"
        else:
            row_data[f"r {r}x"] = 'N/A'
    data_28_q.append(row_data)

df_28_q = pd.DataFrame(data_28_q)
styled_df_28_q = (df_28_q.style.pipe(apply_report_theme)
    .set_caption("各組合使用的 q 值")
)
display(styled_df_28_q)

```

<pandas.io.formats.style.Styler at 0x1184077a0>

<pandas.io.formats.style.Styler at 0x11748b590>

0.0.11 2-5. 結果視覺化

```

[39]: # (a) 影像比較網格：行 = patch_size，列 = 壓縮比
fig, axes = plt.subplots(len(patch_sizes), len(target_ratios) + 1,
    figsize=(3.5 * (len(target_ratios) + 1), 3.5 *
    ↪len(patch_sizes)))

for i, p in enumerate(patch_sizes):
    # 第一列：原始影像
    axes[i, 0].imshow(A, cmap='gray', vmin=0, vmax=255)
    axes[i, 0].set_ylabel(f'patch={p}×{p}', fontsize=10, fontweight='bold')
    if i == 0:
        axes[i, 0].set_title('原始影像', fontsize=9)

```

```

axes[i, 0].axis('off')

for j, r in enumerate(target_ratios):
    ax = axes[i, j + 1]
    if (p, r) in results:
        res = results[(p, r)]
        ax.imshow(res['img'], cmap='gray', vmin=0, vmax=255)
        ax.set_title(f'q={res["q"]}, r={res["actual_ratio"]:.
↪1f}x\nPSNR={res["psnr"]:.1f}dB',
                    fontsize=8)
    else:
        ax.text(0.5, 0.5, 'N/A', ha='center', va='center', transform=ax.
↪transAxes)
    if i == 0:
        ax.set_title(f'目標 {r}x{n' + (ax.get_title() if (p, r) in results_
↪else 'N/A'),
                    fontsize=8)
    ax.axis('off')

plt.suptitle('Patch SVD 影像重建：不同 patch size × 壓縮比', fontsize=13,
↪fontweight='bold')
plt.tight_layout()
plt.show()

```




為何部分實驗結果會出現 NA ？

在 Patch SVD 實驗中，我們觀察到當影像塊（Patch size）較小時，無法實現高倍率的壓縮。其原因在於 SVD 分解後的矩陣儲存開銷：

- **U 矩陣的空間占用：**保留 q 個成分時， U 矩陣需要儲存 $N_p \times q$ 個數值。當 Patch 切得越小，影像塊的總數 N_p 就會急劇增加。
- **壓縮臨界點：**以 1×1 為例，即便 $q = 1$ ， $N_p = m \times n$ ，其壓縮比上限也僅約為 $1x$ ；對於 4×4 ， $q = 1$ 的最高壓縮比約為 $15.9x$ 。因此，在目標設定為 $20x$ 或 $50x$ 時，數學上不存在任何有效的 q 值能達成條件，導致結果為 NA。
- **結論：**影像塊並非越小越好。小尺寸影像塊雖能捕捉局部特徵，但其索引成本過高。在高倍率壓縮需求下，較大的影像塊才能提供有效的壓縮潛力。

0.0.12 2-6. 定量分析與解釋：奇異值熵與有效秩

動機：為了更嚴格地解釋「為什麼小 patch 在高壓縮比下表現較好」，我們需要量化分析各 patch size 下奇異值能量的分佈特性。我們引入兩個核心指標：

1. **奇異值熵 (Singular Value Entropy, SVE)：**定義歸一化能量分佈 $p_i = \sigma_i^2 / \sum \sigma_j^2$ ，則 $H = -\sum_{i=1}^r p_i \log(p_i)$ 。我們使用歸一化熵 $H / \log(r)$ ，其中 r 為 SVD 回傳的奇異值數 ($\text{len}(s)$)，其範圍在 $[0, 1]$ 。

- **為何分母可寫成 $\log(\min(m, n))$** ：對支撐大小為 r 的機率分佈，Shannon 熵滿足 $H \leq \log r$ ，且在 $p_i = 1/r$ （能量平均分散）時取等號；而對任意 $m \times n$ 矩陣，SVD 產生的奇異值個數 $r = \min(m, n)$ ，因此以 $\log(\min(m, n))$ 作為正規化分母並非武斷，而是該維度限制下的理論上界。若矩陣實際秩小於 r （或經閾值裁切後有效支撐變小），真正上界會變成 $\log(\text{rank})$ ；本作業仍用 $\log(\min(m, n))$ 作為保守上界，以維持不同 patch size 間的可比性與穩定性（避免分母隨閾值選擇飄動）。
- **解釋**：歸一化熵越低，代表能量分佈越集中。使用總維度 r 作為分母能更準確地反映相對於「全秩空間」的能量集中度與低秩性（若僅用有效成分數 $\text{len}(p)$ 作為分母，則僅衡量『非零成分間的均勻度』，無法體現相對於系統維度的壓縮潛力）。

2. **有效秩 (Effective Rank)**：計算達到 99% 能量比例所需的成分數 q 。

- **解釋**：有效秩佔總維度 (p^2) 的比例越低，說明該尺度下的局部特徵越容易被稀疏表徵 (Sparse representation)。

驗證目標：計算並比較不同 patch size 的能量集中程度，以數值支持「局部局部同質性如何轉化為壓縮優勢」。

```
[40]: def calculate_sve(s):
    """ 計算歸一化奇異值熵 (Normalized Singular Value Entropy) """
    energy = s**2
    p = energy / np.sum(energy)
    p = p[p > 1e-12] # 排除過小值以避免 log(0)
    entropy = -np.sum(p * np.log(p))
    # 歸一化分母使用 len(s) 而非 len(p)，旨在衡量能量相對於「總潛在維度」的集中度。
    # 這能有效反映系統的低秩性 (Low-rankness)，而非僅是有效成分間的相對均勻度。
    return entropy / np.log(len(s)) if len(s) > 1 else 0.0

def get_threshold_rank(s, threshold=0.99):
    """
    計算達到能量門檻所需的最少成分數。

    注意：此函數返回的是「門檻秩」，非線性代數意義上的「有效秩」。
    有效秩 (effective rank) 在文獻中有多種嚴格定義（如奇異值閾值法）；
    此處僅衡量「達到指定累積能量比例所需的維度」。
    """
    energy_ratio = np.cumsum(s**2) / np.sum(s**2)
    return np.searchsorted(energy_ratio, threshold) + 1

p_list = [8, 16, 32, 64]
sve_vals = []
threshold_rank_ratios = []

plt.figure(figsize=(10, 6))

for p in p_list:
    # 優先從快取中讀取 SVD 結果，避免重複計算
    if 'patch_svd_cache' in globals() and p in patch_svd_cache:
```

```

    s_p = patch_svd_cache[p]['s_p']
else:
    # 提取 Patch 並中心化以觀察純粹的局部變異結構
    pm, _ = extract_patches(A, p)
    pm_centered = pm - pm.mean(axis=0, keepdims=True)
    _, s_p, _ = np.linalg.svd(pm_centered, full_matrices=False)

sve = calculate_sve(s_p)
tr = get_threshold_rank(s_p, 0.99)
sve_vals.append(sve)
# 門檻秩佔比：達到 99% 累積能量所需秩，相對於 patch 維度  $p^2$ 。
threshold_rank_ratios.append(tr / (p*p))


# 繪製歸一化衰減曲線
plt.plot(np.linspace(0, 1, len(s_p)), s_p / s_p[0], label=f'p={p} (SVE={sve:
↪.3f})')

plt.title('不同 Patch Size 的歸一化奇異值衰減對比', fontsize=12)
plt.xlabel('歸一化成分索引 (i / p^2)')
plt.ylabel('歸一化奇異值 (_i / _1)')
plt.legend()
plt.grid(True, alpha=0.3)
plt.show()

data_33 = []
for i, p in enumerate(p_list):
    data_33.append({
        'Patch Size': f"{p}×{p}",
        '歸一化熵 (SVE)': sve_vals[i],
        '門檻秩佔比 (99%)': threshold_rank_ratios[i]
    })

df_33 = pd.DataFrame(data_33)
styled_df_33 = (df_33.style.pipe(apply_report_theme)
    .format({'歸一化熵 (SVE)': '{:.4f}', '門檻秩佔比 (99%)': '{:.2%}'})
    .set_caption("Patch Size 定量分析摘要")
)
display(styled_df_33)
print("分析：")
print("1. 歸一化熵隨 patch size 縮小而下降，說明小 patch 的能量分佈更極端地集中在首個成分。")
print("2. 在高壓縮比（低 q）下，小 patch 保留的能量比例更高，因此重建品質 (PSNR) 較佳。")
print("3. 大 patch 的門檻秩佔比較低，說明大尺度結構具有更強的全局壓縮潛力。")

```



<pandas.io.formats.style.Styler at 0x1169e5490>

分析：

1. 歸一化熵隨 patch size 縮小而下降，說明小 patch 的能量分佈更極端地集中在首個成分。
2. 在高壓縮比（低 q）下，小 patch 保留的能量比例更高，因此重建品質（PSNR）較佳。
3. 大 patch 的門檻秩佔比較低，說明大尺度結構具有更強的全局壓縮潛力。

```
[41]: # (b) PSNR vs 壓縮比連續曲線
colors_map = {8: 'royalblue', 16: 'green', 32: 'darkorange', 64: 'red'}
linestyles_map = {8: '-', 16: '--', 32: '-.', 64: ':'}

fig, ax = plt.subplots(figsize=(11, 6))

for p in patch_sizes:
    if p not in patch_svd_cache:
        continue

    # 重用 Section 2-4 已算好的 SVD 快取
    cache = patch_svd_cache[p]
    U_p = cache['U_p']
    s_p = cache['s_p']
    Vt_p = cache['Vt_p']
    patch_mean = cache['patch_mean']
    meta = cache['meta']
```

```

ratios_curve = []
psnrs_curve = []


# 限制 q 上限為 80：對 256×256 影像而言，q > 80 時壓縮比已降至接近 1x，
# 繼續繪製曲線在視覺上沒有意義，且計算成本隨 q 線性增長。
max_q = min(len(s_p), 80)
for q in range(1, max_q + 1):
    r = patch_compression_ratio(m, n, p, q)
    # 1.1 為壓縮比的實用下界：低於此值代表壓縮後的儲存量僅比原始少不到 10%，
    # 壓縮已失去實際意義，故不納入曲線。
    if r < 1.1:
        break

    # 利用快取重建
    patch_rec = (U_p[:, :q] * s_p[:, q]) @ Vt_p[:, q, :] + patch_mean
    img_rec = np.clip(reconstruct_from_patches(patch_rec, meta, p), 0, 255)
    ratios_curve.append(r)
    psnrs_curve.append(psnr(A, img_rec))

if ratios_curve:
    ax.plot(ratios_curve, psnrs_curve,
            color=colors_map.get(p, 'gray'),
            linestyle=linestyles_map.get(p, '-'),
            linewidth=2, marker='o', markersize=4,
            label=f'patch={p}×{p}')

ax.axhline(y=30, color='k', linestyle='--', alpha=0.5, linewidth=1.5,
           label='PSNR = 30dB')
ax.set_xlabel('壓縮比 (倍) ', fontsize=11)
ax.set_ylabel('PSNR (dB) ', fontsize=11)
ax.set_title('PSNR vs 壓縮比：不同 Patch Size 比較\n(x 軸已反轉：高壓縮比位於右方)',
             fontsize=12, fontweight='bold')
ax.legend(fontsize=10)
ax.grid(True, alpha=0.3)
ax.invert_xaxis()      # 高壓縮比在右方，便於閱讀
plt.tight_layout()
plt.show()

```



觀察與分析 (嚴謹性補充)：

透過 Section 2-3b 的定量指標，我們可以對 Patch Size 的表現給出更深層的數學解釋：

1. **高壓縮比 (High Compression Ratio) 區間：**當壓縮比極高時，我們能保留的成分 q 往往僅剩 1~2 個。定量分析顯示較小的 patch (本實驗中以 $p = 8$ 為代表) 具備較低的歸一化奇異值熵 (SVE)。這意味著在局部尺度上，影像資訊更集中於前幾個奇異值，因此在低 q 條件下通常能保留較多主要結構。
2. **中低壓縮比 (Low Compression Ratio) 區間：**隨著可儲存數值增加，大 patch (如 $p = 16$) 開始展現優勢。雖然大 patch 的 SVE 較高，但其門檻秩佔總維度的比例卻低於小 patch。這說明在較大的感受野下，影像的全局結構具有更強的可壓縮性。一旦 q 足夠覆蓋其門檻秩，大 patch 就能比小 patch 更精確地重建細膩的邊緣與紋理，導致 PSNR 曲線發生交叉 (如 2-5(b) 圖所示)。
3. **最佳化路徑：**實驗數據表明，最佳壓縮策略應隨目標壓縮比動態調整 Patch Size。這與小波變換 (Wavelet transform) 的多尺度分析思想不謀而合：局部精細特徵與全局結構分佈在不同的頻譜能量尺度上。

各壓縮比下的最佳 Patch Size 摘要 (基於 PSNR 對照表)：

目標壓縮比	最佳 Patch Size	說明
高壓縮	較小 patch (如 $p = 8$)	前幾個奇異值較集中，在低 q 下通常較有利
中壓縮	需依修正後壓縮比重新比較	patch mean 的儲存成本會改變不同 patch 的可行區間

目標壓縮比	最佳 Patch Size	說明
低壓縮	較大 patch 可能開始佔優	感受野較大時，若壓縮比要求不高，較能重建全域細節

結論：最優 patch size 隨目標壓縮比而改變，不存在一個對所有壓縮比均最優的單一 patch size。

0.0.13 2-7. 多張影像比較（增加幾何紋理圖 ascent）

動機：在 2-1 節的目標中提到將比較「多張影像」。目前 Section 2 主要以浣熊影像 (Raccoon) 為例，該圖包含許多細碎毛髮，屬於雜亂紋理 (Random-like texture)；而 `scipy.datasets.ascent()` 則是典型的幾何、直線紋理豐富的影像。本節透過這兩張影像的對比，探討不同紋理特性對最佳 patch size 選擇的影響。

```
[42]: # 載入第二張影像：ascent（具備豐富幾何紋理）
A_ascent_raw = scipy.datasets.ascent().astype(np.float64)
zoom_factor_ascent = (256 / A_ascent_raw.shape[0], 256 / A_ascent_raw.shape[1])
A_ascent = zoom(A_ascent_raw, zoom_factor_ascent)
A_ascent = np.clip(A_ascent, 0, 255)

def run_patch_svd_experiment(img, p_sizes, t_ratios):
    res_psnr = {}
    for p in p_sizes:
        patch_mat, meta = extract_patches(img, p)
        patch_mean = patch_mat.mean(axis=0, keepdims=True)
        patch_centered = patch_mat - patch_mean
        U_p, s_p, Vt_p = np.linalg.svd(patch_centered, full_matrices=False)
        for target_r in t_ratios:
            best_q = 0
            for q_try in range(1, len(s_p) + 1):
                if patch_compression_ratio(256, 256, p, q_try) >= target_r:
                    best_q = q_try
            else:
                break
            if best_q > 0:
                patch_rec = (U_p[:, :best_q] * s_p[:best_q]) @ Vt_p[:, :best_q, :]
                ↪ patch_mean
                img_rec = np.clip(reconstruct_from_patches(patch_rec, meta, p),
                ↪ 0, 255)
                res_psnr[(p, target_r)] = psnr(img, img_rec)
    return res_psnr

# 執行實驗 (results 變數來自前文對 raccoon 的計算)
psnr_raccoon = {(p, r): results[(p, r)]['psnr'] for (p, r) in results if (p, r)
↪ in results}
```

```


psnr_ascent = run_patch_svd_experiment(A_ascent, patch_sizes, target_ratios)

# 繪製 PSNR 隨壓縮比變化的曲線 (對比 Raccoon vs Ascent)
fig, axes = plt.subplots(1, 2, figsize=(14, 5), sharey=True)
p_colors = {8: 'royalblue', 16: 'green', 32: 'darkorange', 64: 'red'}

for i, (name, psnr_res) in enumerate([('Raccoon (雜亂紋理)', psnr_raccoon),
    ↳('Ascent (幾何紋理)', psnr_ascent)]):
    for p in patch_sizes:
        r_list = [r for (pp, r) in psnr_res if pp == p]
        psnr_list = [psnr_res[(p, r)] for r in r_list]
        # 排序以便連線
        sort_idx = np.argsort(r_list)
        axes[i].plot(np.array(r_list)[sort_idx], np.array(psnr_list)[sort_idx],
            'o-', label=f'patch={p}', color=p_colors[p])
    axes[i].set_title(name)
    axes[i].set_xlabel('目標壓縮比 (x)')
    axes[i].set_ylabel('PSNR (dB)')
    axes[i].legend()
    axes[i].grid(True, alpha=0.3)

plt.suptitle('多張影像在不同 Patch Size 下之壓縮品質比較', fontsize=14,
    ↳fontweight='bold')
plt.tight_layout()
plt.show()

```



觀察與討論：

1. 紋理特性對最佳 Patch Size 的影響：

- 在 Raccoon (細碎毛髮) 中，較小的 patch ($p = 8$ 或 16) 在多數壓縮比下表現較佳，因為小塊能更靈活地捕捉雜亂且不連續的細節。
- 在 Ascent (幾何直線多) 中，可以觀察到各 patch size 之間的 PSNR 差距相對較小，且較大 patch ($p = 32$) 的表現相較於 raccoon 有所提升。這是因為幾何影像的局部結構在較大尺度上仍具備高度方向一致性，使得大 patch 的 SVD 能量集中度得以維持。

2. **共同規律**：無論哪種影像，當壓縮比要求極高（如 50x）時，小 patch 通常是穩定維持基本輪廓且不發生維度災難（儲存開銷過大）的優先選擇。

結論：影像的紋理複雜度越高，建議使用較小的 patch 以保留細節；而對於結構化程度高的影像，適度增大 patch size 可以利用空間相關性，但在本實驗 256x256 的基準下， 8×8 與 16×16 仍是兼顧品質與壓縮潛力的平衡選擇。

0.0.14 2-7b. 四張影像的 Patch SVD 系統比較

動機：我們想觀察 Patch SVD 在不同類型紋理下的表現。除了具備複雜毛髮紋理的 Raccoon 與具備幾何結構的 Ascent 外，我們加入兩種極端情況：平滑漸層（極低複雜度）與棋盤格（高頻重複紋理）。

```
[43]: # 準備四張影像（都 resize 到 256x256 灰階）
img_raccoon = A.copy() # 重用前置載入步驟已定義的 A (raccoon)

# Ascent (重用 Section 2-7 已定義的 A_ascent, 若無則重新載入)
try:
    img_ascent = A_ascent.copy()
except NameError:
    img_ascent_raw = scipy.datasets.ascent().astype(np.float64)
    img_ascent = zoom(img_ascent_raw, (256/img_ascent_raw.shape[0], 256/
    ↪img_ascent_raw.shape[1]))
    img_ascent = np.clip(img_ascent, 0, 255)

# 3. 合成平滑漸層影像
img_smooth = np.outer(np.linspace(0, 255, 256), np.ones(256))

# 4. 合成棋盤格影像
img_checker = np.kron(np.indices((16, 16)).sum(axis=0) % 2, np.ones((16, 16)))
↪* 255

images_compare = {
    "Raccoon (雜亂紋理)": img_raccoon,
    "Ascent (幾何紋理)": img_ascent,
    "Smooth Gradient (低複雜度)": img_smooth,
    "Checkerboard (高頻重複)": img_checker
}

patch_sizes_comp = [8, 16, 32]
target_ratios_comp = [5, 10, 20, 50]

fig, axes = plt.subplots(4, 1, figsize=(10, 20))
colors_map_comp = {8: 'royalblue', 16: 'green', 32: 'darkorange'}

data_summary = []

for idx, (name, img) in enumerate(images_compare.items()):
```

```

ax = axes[idx]
for p in patch_sizes_comp:
    p_mat, meta = extract_patches(img, p)
    p_mean = p_mat.mean(axis=0, keepdims=True)
    p_centered = p_mat - p_mean
    Up, sp, Vtp = np.linalg.svd(p_centered, full_matrices=False)

    ratios_plot = []
    psnrs_plot = []

    for tr in target_ratios_comp:
        best_q = 0
        for q_try in range(1, len(sp) + 1):
            if patch_compression_ratio(256, 256, p, q_try) >= tr:
                best_q = q_try
            else:
                break

        if best_q > 0:
            p_rec = (Up[:, :best_q] * sp[:best_q]) @ Vtp[:, best_q, :] + p_mean
            img_rec = np.clip(reconstruct_from_patches(p_rec, meta, p), 0, 255)

            actual_r = patch_compression_ratio(256, 256, p, best_q)
            p_val = psnr(img, img_rec)

            ratios_plot.append(actual_r)
            psnrs_plot.append(p_val)
            data_summary.append({
                '影像類型': name,
                'Patch': f'{p}x{p}',
                '目標比例': tr,
                '實際比例': actual_r,
                'PSNR': p_val
            })

    ax.plot(ratios_plot, psnrs_plot, 'o-', color=colors_map_comp[p],
            label=f'Patch {p}x{p}')

    ax.set_title(name)
    ax.set_xlabel('Compression Ratio (x)')
    ax.set_ylabel('PSNR (dB)')
    ax.legend()
    ax.grid(True, alpha=0.3)
    ax.invert_xaxis()

```


```

plt.suptitle('四張不同特徵影像的 Patch SVD 效能比較', fontsize=16,
            ↪fontweight='bold', y=1.02)
plt.tight_layout()
plt.show()

df_summary = pd.DataFrame(data_summary)
styled_df_summary = (df_summary.style.pipe(apply_report_theme)
                    .format({'實際比例': '{:.1f}x', 'PSNR': '{:.2f}'})
                    .background_gradient(subset=['PSNR'], cmap='Blues')
                    .set_caption("四張影像不同 Patch Size 比較")
                    )
display(styled_df_summary)

```

四張不同特徵影像的 Patch SVD 效能比較



```

/Users/moses/Documents/Moses/01_Academic/Programming/Shallow_Machine_Learning/ml
_course/.venv/lib/python3.12/site-packages/pandas/io/formats/style.py:4209:
RuntimeWarning: invalid value encountered in scalar multiply
    norm = _matplotlib.colors.Normalize(smin - (rng * low), smax + (rng * high))
<pandas.io.formats.style.Styler at 0x117219fa0>

```

觀察與數學分析：

在此對照實驗中，我們觀察到 **Smooth Gradient** 與 **Checkerboard** 在所有設定下的 PSNR 皆為 inf （無窮大）。這並非程式錯誤，而是主動設計的極端低秩對照組：

1. **Smooth Gradient (低複雜度)**：此影像由一個垂直向量與全 1 向量的外積 (Outer product) 生成，其全域矩陣的 rank 為 1。在 Patch SVD 中，每個 $p \times p$ 的小塊本質上仍是常數或簡單線性變化，其局部 rank 極低。當 $q \geq 1$ 時，SVD 即可達成 100% 的能量重建 (MSE=0)，故 PSNR 為 inf 。
2. **Checkerboard (高頻重複)**：雖然視覺上呈現高頻變化，但棋盤格具有極強的結構對稱性。在 8×8 以上的 patch size 下，其內部僅包含固定的幾種基底模式（常數或交替向量），本質上是 rank-2 結構。因此只要 $q \geq 2$ ，就能完美還原影像訊號。

結論：此實驗驗證了 **SVD 壓縮效能高度取決於影像的低秩性 (Low-rankness)**。自然影像（如 Raccoon）因包含隨機雜訊與複雜細節，其奇異值衰減較慢，難以達成完美重建；而合成影像的結構規律性讓我們能量化觀察到 SVD 如何在極低維度下捕捉完整訊號。

0.0.15 2-7c. 直接對比：Patch SVD vs. 全域 SVD (Raccoon)

動機：Section 2 引入 Patch SVD 的理由是「全域 SVD 遺漏局部紋理」。本節直接驗證這一假設——在相同壓縮比下，Patch SVD 是否真的能比全域 SVD 提供更好的重建品質？

```

[44]: target_ratios_direct = [5, 10, 20, 50, 100]
      patch_sizes_direct = [8, 16, 32]

      # 全域 SVD 數據 (重用 Section 1-1 的 U, s, Vt, 對應 Raccoon 影像 A)
      global_ratios_d = []
      global_psnrs_d = []

      for tr in target_ratios_direct:
          best_q = 0
          for q_try in range(1, len(s) + 1):
              if get_compression_ratio(256, 256, q_try) >= tr:
                  best_q = q_try
              else:
                  break
          if best_q > 0:
              A_q = svd_reconstruct(U, s, Vt, best_q)
              A_q_clipped = img_finalize(A_q)
              actual_r = get_compression_ratio(256, 256, best_q)
              p_val = psnr(A, A_q_clipped)

```

```

        global_ratios_d.append(actual_r)
        global_psnrs_d.append(p_val)

plt.figure(figsize=(10, 6))
# 全域 SVD 曲線
plt.plot(global_ratios_d, global_psnrs_d, 'ks--', linewidth=2.5, markersize=8,
        ↪label='Global SVD (Section 1-1)')

# Patch SVD 數據 (重用 patch_svd_cache 中的分解結果)
colors_direct = {8: 'royalblue', 16: 'green', 32: 'darkorange'}
for p in patch_sizes_direct:
    p_ratios_d = []
    p_psnrs_d = []

    # 從快取獲取 SVD 結果
    cache = patch_svd_cache[p]
    Up, sp, Vtp = cache['U_p'], cache['s_p'], cache['Vt_p']
    p_mean, meta = cache['patch_mean'], cache['meta']

    for tr in target_ratios_direct:
        best_q = 0
        for q_try in range(1, len(sp) + 1):
            if patch_compression_ratio(256, 256, p, q_try) >= tr:
                best_q = q_try
            else:
                break
        if best_q > 0:
            p_rec = (Up[:, :best_q] * sp[:best_q]) @ Vtp[:, best_q, :] + p_mean
            img_rec = np.clip(reconstruct_from_patches(p_rec, meta, p), 0, 255)
            actual_r = patch_compression_ratio(256, 256, p, best_q)
            p_val = psnr(A, img_rec)
            p_ratios_d.append(actual_r)
            p_psnrs_d.append(p_val)

    plt.plot(p_ratios_d, p_psnrs_d, 'o-', color=colors_direct[p], label=f'Patch_
    ↪SVD ({p}x{p})')

plt.title('Patch SVD vs. Global SVD 直接對比 (Raccoon)', fontsize=14,
        ↪fontweight='bold')
plt.xlabel('Compression Ratio (x)')
plt.ylabel('PSNR (dB)')
plt.legend()
plt.grid(True, alpha=0.3)
plt.gca().invert_xaxis()
plt.show()


print("觀察與分析：")

```

```

print("1. 在低壓縮比區間 (如 < 10x), 全域 SVD 往往表現更好。這是因為全域 SVD 不需要  
像 Patch SVD 那樣")
print(" 為每個 patch 儲存均值向量 (patch mean), 因此其儲存效率在低壓縮比下更高。  
")
print("2. 在中高壓縮比區間, Patch SVD (特別是較小尺寸如 8x8) 開始展現其「局部適應性」  
的優勢。")
print(" 即便壓縮比相同, Patch SVD 能更好地保留局部細節, 而全域 SVD 在極低 rankL  
↳ 下容易產生模糊或嚴重的全域偽影。")
print("3. 結論: 全域 SVD 適合全域結構明顯且壓縮需求不極端的場景; Patch SVD 則在需要  
高壓縮比且影像包含豐富局部紋理時, ")
print(" 能提供更好的重建品質。")

```



觀察與分析：

1. 在低壓縮比區間 (如 < 10x), 全域 SVD 往往表現更好。這是因為全域 SVD 不需要像 Patch SVD 那樣為每個 patch 儲存均值向量 (patch mean), 因此其儲存效率在低壓縮比下更高。
2. 在中高壓縮比區間, Patch SVD (特別是較小尺寸如 8x8) 開始展現其「局部適應性」的優勢。即便壓縮比相同, Patch SVD 能更好地保留局部細節, 而全域 SVD 在極低 rank 下容易產生模糊或嚴重的全域偽影。
3. 結論: 全域 SVD 適合全域結構明顯且壓縮需求不極端的場景; Patch SVD 則在需要高壓縮比且影像包含豐富局部紋理時, 能提供更好的重建品質。

0.0.16 3-0. 資料載入

動機：影像資料集 (image dataset) 的 SVD 與單張影像的 SVD 有本質差異：矩陣的**每一列是一張影像** (每個觀測)，奇異向量捕捉的是**跨影像的共同結構** (特徵臉)。這讓 SVD 具有降維的意義，可作為人臉辨識的特徵提取方法 (Eigenfaces 方法)。

Olivetti Faces 資料集包含 40 人各 10 張共 400 張 64×64 的灰階人臉影像。

本節驗證目標：載入資料，初步視覺化，計算 Eigenfaces，量化 rank- q 重建品質，為人臉辨識的特徵向量數量選擇提供量化依據。

```
[45]: faces_data = fetch_olivetti_faces(shuffle=False, random_state=42)
X = faces_data['data']          # type: ignore
X_images = faces_data['images'] # type: ignore
y = faces_data['target']        # type: ignore

print(f"資料集形狀 (展平) : {X.shape}")
print(f"影像形狀 : {X_images.shape}")
print(f"類別數 (受試者) : {len(np.unique(y))}")
print(f"每人張數 : {np.sum(y == 0)}")
print(f"像素值範圍 : [{X.min():.3f}, {X.max():.3f}]")
```

資料集形狀 (展平) : (400, 4096)

影像形狀 : (400, 64, 64)

類別數 (受試者) : 40

每人張數 : 10

像素值範圍 : [0.000, 1.000]

0.0.17 3-1. 初步視覺化

```
[46]: rng = np.random.RandomState(42)

# (a) 隨機顯示 50 張
random_idx = rng.choice(400, 50, replace=False)
fig, axes = plt.subplots(5, 10, figsize=(15, 8))
for ax, idx in zip(axes.flat, random_idx):
    ax.imshow(X_images[idx], cmap='gray', vmin=0, vmax=1)
    ax.set_title(f'#{idx}\nS{y[idx]}', fontsize=6)
    ax.axis('off')
plt.suptitle('50 張隨機人臉', fontsize=14, fontweight='bold')
plt.tight_layout()
plt.show()

# (b) 每位受試者隨機 1 張，共 40 張
fig, axes = plt.subplots(4, 10, figsize=(15, 7))
for subject in range(40):
    subject_idx = np.where(y == subject)[0]
    chosen = rng.choice(subject_idx)
    ax = axes[subject // 10, subject % 10]
```



```

ax.imshow(X_images[chosen], cmap='gray', vmin=0, vmax=1)
ax.set_title(f'S{subject}', fontsize=8)
ax.axis('off')
plt.suptitle('每位受試者隨機一張 (共 40 人)', fontsize=14, fontweight='bold')
plt.tight_layout()
plt.show()

# (c) Subject 0 全部 10 張
subject_0_idx = np.where(y == 0)[0]
fig, axes = plt.subplots(2, 5, figsize=(12, 5))
for ax, idx in zip(axes.flat, subject_0_idx):
    ax.imshow(X_images[idx], cmap='gray', vmin=0, vmax=1)
    ax.set_title(f'影像 #{idx}', fontsize=9)
    ax.axis('off')
plt.suptitle('受試者 0 的全部 10 張影像', fontsize=14, fontweight='bold')
plt.tight_layout()
plt.show()

```





0.0.18 3-2. 資料前處理與均值臉

Eigenfaces 演算法的第一步：計算並移除均值臉，讓後續的 SVD 捕捉「偏離平均外觀的方向」。

數學：設人臉矩陣 $A \in \mathbb{R}^{400 \times 4096}$ (每列是一張展平的人臉)。均值臉(mean face)為 $\bar{a} = \frac{1}{400} \sum_{i=1}^{400} a_i \in \mathbb{R}^{4096}$ 。中心化矩陣 $\tilde{A} = A - \mathbf{1}\bar{a}^T$ 。

均值臉代表資料集的「基準外觀」——一張具有所有受試者平均特徵的「平均人臉」。後續的 Eigenfaces 捕捉的是偏離這個均值的主要方向。

```
[47]: # 建立影像矩陣，轉回 [0, 255]
A_faces = X.copy() * 255      # shape: (400, 4096)

# 計算並顯示平均臉
```

```

mean_face_vec = A_faces.mean(axis=0)          # shape: (4096,)
mean_face = mean_face_vec.reshape(64, 64)

fig, ax = plt.subplots(figsize=(5, 4))
ax.imshow(mean_face, cmap='gray', vmin=0, vmax=255)
ax.set_title('平均臉 (Mean Face) ', fontsize=11)
ax.axis('off')
plt.tight_layout()
plt.show()
print(f"平均臉像素值範圍：[{mean_face.min():.1f}, {mean_face.max():.1f}]")

# 中心化 (對每個像素位置減去均值)
A_faces_centered = A_faces - mean_face_vec    # shape (400, 4096) - (4096,)
print(f"中心化後均值：{A_faces_centered.mean():.2e} (接近 0) ")
print(f"中心化後 std：{A_faces_centered.std():.3f}")

```

平均臉 (Mean Face)



平均臉像素值範圍：[61.6, 190.3]
 中心化後均值：-1.37e-05 (接近 0)
 中心化後 std：35.396

0.0.19 3-3. 完整 SVD 分解與能量分析

數學：對中心化人臉矩陣 $\tilde{A} \in \mathbb{R}^{400 \times 4096}$ 做 SVD：

$$\tilde{A} = U\Sigma V^T$$

其中 V 的各列（右奇異向量，shape $4096 = 64 \times 64$ ）就是 **Eigenfaces**——人臉空間的主要變化方向。

由於 $400 < 4096$ ，使用 `full_matrices=False` 可得到 $U \in \mathbb{R}^{400 \times 400}$ 、 $\Sigma \in \mathbb{R}^{400}$ 、 $V^T \in \mathbb{R}^{400 \times 4096}$ ，大幅節省記憶體。

```
[48]: print("進行 SVD 分解 (400×4096 矩陣) ...")
U_f, s_f, Vt_f = np.linalg.svd(A_faces_centered, full_matrices=False)
print(f"完成! U: {U_f.shape}, s: {s_f.shape}, Vt: {Vt_f.shape}")

# 能量分析
energy_f = s_f ** 2
total_f = np.sum(energy_f)
energy_ratio_f = np.cumsum(energy_f) / total_f

thresholds_f = [0.80, 0.90, 0.95, 0.99]
q_f = {}
for t in thresholds_f:
    q_f[t] = int(np.searchsorted(energy_ratio_f, t)) + 1

fig, axes = plt.subplots(1, 2, figsize=(14, 5))

axes[0].semilogy(s_f, 'b-', linewidth=1.5)
axes[0].set_xlabel('成分索引')
axes[0].set_ylabel('奇異值 (log scale)')
axes[0].set_title('人臉資料奇異值分布')
axes[0].grid(True, alpha=0.3)

axes[1].plot(np.arange(1, len(energy_ratio_f)+1), energy_ratio_f, 'g-',
             linewidth=1.5)
colors_f = ['blue', 'orange', 'red', 'purple']
for (t, q_k), c in zip(q_f.items(), colors_f):
    axes[1].axvline(x=q_k, color=c, linestyle='--', alpha=0.7)
    axes[1].axhline(y=t, color=c, linestyle=':', alpha=0.5)
    axes[1].plot(q_k, energy_ratio_f[q_k-1], 'o', color=c, markersize=8,
                 label=f'{int(t*100)}%: q={q_k}')
axes[1].set_xlabel('成分數 q')
axes[1].set_ylabel('累積能量比例')
axes[1].set_title('人臉資料累積能量分布')
axes[1].legend(fontsize=9)
axes[1].grid(True, alpha=0.3)

plt.suptitle('Olivetti Faces SVD 能量分析', fontsize=14, fontweight='bold')
plt.tight_layout()
plt.show()
```


```

data_51 = []
for t in thresholds_f:
    q_k = q_f[t]
    data_51.append({
        '累積能量門檻': f"{int(t*100)}%",
        '所需 q 個數 (特徵向量)': q_k
    })

df_51 = pd.DataFrame(data_51)
styled_df_51 = (df_51.style.pipe(apply_report_theme)
    .set_caption(f"人臉資料能量摘要 (總奇異值數: {len(s_f)}, 前 10 個奇異值佔總能量比例: {energy_ratio_f[9]:.1%})")
)
display(styled_df_51)

```

進行 SVD 分解 (400×4096 矩陣) ...
 完成! U: (400, 400), s: (400,), Vt: (400, 4096)



<pandas.io.formats.style.Styler at 0x1189711c0>

觀察——人臉資料 vs 自然影像的能量集中性：

比較 Section 1 的自然影像（浣熊）與 Section 3 的人臉資料集，人臉資料的能量通常更為集中：

- 人臉資料：前幾個成分即可涵蓋大比例的累積能量（如前 10 個成分約佔 70%+ 能量）
- 自然影像：能量衰減相對較慢

原因：人臉影像的結構具有**高度規律性**——所有人臉都有相似的眼睛、鼻子、嘴巴位置，只在細節（表情、光影、個人特徵）上有差異。這種強烈的共同結構使得少數主方向（Eigenfaces）足以描述整個人臉空間的主要變化。

數學上，這意味著人臉矩陣的有效秩（effective rank）遠小於理論上限（ $\min(400, 4096) = 400$ ），低秩近似的效果特別好。

0.0.20 3-4. Eigenfaces 展示

數學： V^T 的第 i 行（即 $\mathbf{v}_i^T$ ，shape 4096）是第 i 個右奇異向量，reshape 成 64×64 後就是第 i 個 Eigenface。

第 i 個 Eigenface 對應的奇異值 σ_i 越大，代表這個方向解釋的人臉變異越多。前幾個 Eigenfaces 通常對應整體亮度、光照方向等全域變化；後期的 Eigenfaces 則捕捉細微的局部特徵差異。

顯示說明：由於特徵向量包含正負值，下圖使用對稱的色彩範圍（ $\text{vmin}=-\text{vmax}$ ），其中亮度代表正向變異強度，暗度代表負向變異強度，中性灰則代表無變異（0）。這顯示的是特徵權重的相對分佈，而非絕對像素值。

```
[49]: fig, axes = plt.subplots(5, 10, figsize=(15, 8))
      for i, ax in enumerate(axes.flat):
          eigenface = Vt_f[i].reshape(64, 64)
          energy_pct = (s_f[i] ** 2 / total_f) * 100

          # 正規化顯示：使用對稱的 vmin/vmax 確保 0 位於中性灰，並說明為相對強度
          vmax = np.max(np.abs(eigenface))
          im = ax.imshow(eigenface, cmap='gray', vmin=-vmax, vmax=vmax)

          ax.set_title(f'EF #{i+1}\n{energy_pct:.1f}%', fontsize=7)
          ax.axis('off')

      # 加入側邊 colorbar 說明相對強度
      fig.subplots_adjust(right=0.92)
      cbar_ax = fig.add_axes([0.94, 0.15, 0.015, 0.7])
      fig.colorbar(im, cax=cbar_ax, label='相對權重強度 (Relative Weight)')

      plt.suptitle('前 50 個特徵臉 (Eigenfaces)\n亮度代表正權重，暗度代表負權重，中性灰代表 0',
                   fontsize=12, fontweight='bold')
      plt.show()

      print(f"前 10 個 Eigenfaces 個別能量比例：")
      for i in range(10):
          print(f" EF #{i+1:>2} : {s_f[i]**2/total_f*100:.2f}%")
```



前 10 個 Eigenfaces 個別能量比例：

EF # 1 : 23.81%
 EF # 2 : 13.99%
 EF # 3 : 7.97%
 EF # 4 : 5.00%
 EF # 5 : 3.61%
 EF # 6 : 3.16%
 EF # 7 : 2.43%
 EF # 8 : 2.04%
 EF # 9 : 1.96%
 EF #10 : 1.67%

0.0.21 3-5. rank-q 重建品質分析

```
[50]: q_values_f = [1, 5, 10, 20, 50, 100, 200, 300]
psnr_stats = []
all_psnr_data = []
ssim_stats = []
all_ssim_data = []

for q in q_values_f:
    A_reconstructed = svd_reconstruct(U_f, s_f, Vt_f, q, mean_vec=mean_face_vec)

    # 向量化 PSNR ; SSIM 逐張 (對人臉結構相似性較敏感)
    clipped = img_finalize(A_reconstructed)
    psnr_vals = psnr(A_faces, clipped, axis=-1)
    ssim_vals = ssim_metric(A_faces, clipped, axis=-1, img_shape=(64, 64))
```

```

psnr_stats.append({
    'q': q,
    'mean': np.mean(psnr_vals),
    'std': np.std(psnr_vals),
    'min': np.min(psnr_vals),
    'max': np.max(psnr_vals)
})
all_psnr_data.append(psnr_vals)

ssim_stats.append({
    'q': q,
    'mean': np.mean(ssim_vals),
    'std': np.std(ssim_vals),
    'min': np.min(ssim_vals),
    'max': np.max(ssim_vals)
})
all_ssim_data.append(ssim_vals)

avg_psnr_per_q = [stat['mean'] for stat in psnr_stats]
min_psnr_per_q = [stat['min'] for stat in psnr_stats]
avg_ssim_per_q = [stat['mean'] for stat in ssim_stats]
min_ssim_per_q = [stat['min'] for stat in ssim_stats]

# 找到平均 PSNR > 30dB 的最小 q
q_30dB = next((stat['q'] for stat in psnr_stats if stat['mean'] >= 30), None)

# 畫圖：上列 PSNR、下列 SSIM (皆含趨勢 + 箱型圖)
fig, axes = plt.subplots(2, 2, figsize=(16, 10))

axes[0, 0].plot(q_values_f, avg_psnr_per_q, 'b-o', linewidth=2, markersize=8,
    ↪label='平均 PSNR')
axes[0, 0].plot(q_values_f, min_psnr_per_q, 'r--x', linewidth=1.5,
    ↪markersize=6, label='最小 PSNR')
axes[0, 0].axhline(y=30, color='gray', linestyle=':', linewidth=1.5,
    ↪label='30dB 門檻')
axes[0, 0].set_xlabel('保留成分數 q', fontsize=11)
axes[0, 0].set_ylabel('PSNR (dB)', fontsize=11)
axes[0, 0].set_title('人臉重建品質趨勢：平均值 vs 最小值 (PSNR) ', fontsize=12,
    ↪fontweight='bold')
axes[0, 0].legend(fontsize=10)
axes[0, 0].grid(True, alpha=0.3)

axes[0, 1].boxplot(all_psnr_data, tick_labels=q_values_f, showliers=True)
axes[0, 1].axhline(y=30, color='r', linestyle=':', linewidth=1.5)
axes[0, 1].set_xlabel('保留成分數 q', fontsize=11)
axes[0, 1].set_ylabel('PSNR (dB)', fontsize=11)

```



```

axes[0, 1].set_title('PSNR 分佈情況 (400 張人臉)', fontsize=12,
    ↪fontweight='bold')
axes[0, 1].grid(True, alpha=0.3)

axes[1, 0].plot(q_values_f, avg_ssim_per_q, 'g-o', linewidth=2, markersize=8,
    ↪label='平均 SSIM')
axes[1, 0].plot(q_values_f, min_ssim_per_q, 'm--x', linewidth=1.5,
    ↪markersize=6, label='最小 SSIM')
axes[1, 0].axhline(y=0.95, color='gray', linestyle=':', linewidth=1.5,
    ↪label='SSIM=0.95 參考')
axes[1, 0].set_xlabel('保留成分數 q', fontsize=11)
axes[1, 0].set_ylabel('SSIM', fontsize=11)
axes[1, 0].set_title('人臉重建品質趨勢：平均值 vs 最小值 (SSIM) ', fontsize=12,
    ↪fontweight='bold')
axes[1, 0].set_ylim(0, 1.02)
axes[1, 0].legend(fontsize=10)
axes[1, 0].grid(True, alpha=0.3)

axes[1, 1].boxplot(all_ssim_data, tick_labels=q_values_f, showliers=True)
axes[1, 1].axhline(y=0.95, color='r', linestyle=':', linewidth=1.5)
axes[1, 1].set_xlabel('保留成分數 q', fontsize=11)
axes[1, 1].set_ylabel('SSIM', fontsize=11)
axes[1, 1].set_title('SSIM 分佈情況 (400 張人臉)', fontsize=12,
    ↪fontweight='bold')
axes[1, 1].set_ylim(0, 1.02)
axes[1, 1].grid(True, alpha=0.3)

plt.tight_layout()
plt.show()

data_56 = []
for stat_p, stat_s in zip(psnr_stats, ssim_stats):
    q = stat_p['q']
    note = " ← 平均達標" if q == q_30dB else ""
    if stat_p['min'] >= 30 and note == "":
        note = " ← 全部達標"
    elif stat_p['min'] < 30 and stat_p['mean'] >= 30:
        note += " (仍有受試者 < 30dB)"

    data_56.append({
        'q': q,
        '平均 PSNR': stat_p['mean'],
        '平均 SSIM': stat_s['mean'],
        'min PSNR': stat_p['min'],
        'min SSIM': stat_s['min'],
        '備注': note
    })

```


```

})

df_56 = pd.DataFrame(data_56)
styled_df_56 = (df_56.style.pipe(apply_report_theme)
    .format({'平均 PSNR': '{:.2f}', '平均 SSIM': '{:.4f}', 'min PSNR': '{:.2f}', 'min SSIM': '{:.4f}'})
    .background_gradient(subset=['平均 PSNR', '平均 SSIM'], cmap='Blues')
    .set_caption("人臉重建品質詳細摘要 (PSNR + SSIM)")
)
display(styled_df_56)

if q_30dB:
    print(f"\n結論：達到平均 PSNR 30dB 需要 q = {q_30dB}。")
    print(f"但觀察分佈可知，在 q={q_30dB} 時最小值僅為 {next(stat['min'] for stat in psnr_stats if stat['q']==q_30dB):.2f}dB，")
    print(f"若要求『所有』受試者重建品質皆達 30dB，則建議 q 應提高至更高數值。")

```



<pandas.io.formats.style.Styler at 0x118c00e90>

結論：達到平均 PSNR 30dB 需要 $q = 200$ 。
 但觀察分佈可知，在 $q=200$ 時最小值僅為 31.88dB，
 若要求『所有』受試者重建品質皆達 30dB，則建議 q 應提高至更高數值。

```

[51]: # 3 位受試者的視覺比較
selected_subjects = [0, 10, 20]
q_display = [5, 20, 50, 100, 200]

# 預先計算各 q 值的完整重建矩陣，避免在受試者迴圈中重複重建 400 張人臉
reconstructed_cache = {
    q: np.clip(svd_reconstruct(U_f, s_f, Vt_f, q, mean_vec=mean_face_vec), 0, 255)
    for q in q_display
}

fig, axes = plt.subplots(len(selected_subjects), len(q_display) + 1,
                        figsize=(3 * (len(q_display) + 1), 3.2 * len(selected_subjects)))

for row, subj in enumerate(selected_subjects):
    subj_idx = np.where(y == subj)[0][0] # 取第一張


    # 原圖
    axes[row, 0].imshow(A_faces[subj_idx].reshape(64, 64), cmap='gray', vmin=0, vmax=255)
    axes[row, 0].set_ylabel(f'受試者 #{subj}', fontsize=10, fontweight='bold')
    if row == 0:
        axes[row, 0].set_title('原始', fontsize=9)
        axes[row, 0].axis('off')

    for col, q in enumerate(q_display):
        face_rec = reconstructed_cache[q][subj_idx].reshape(64, 64)
        p_val = psnr(A_faces[subj_idx], reconstructed_cache[q][subj_idx])

        axes[row, col + 1].imshow(face_rec, cmap='gray', vmin=0, vmax=255)
        if row == 0:
            axes[row, col + 1].set_title(f'q={q}\n{p_val:.1f}dB', fontsize=9)
        else:
            axes[row, col + 1].set_title(f'{p_val:.1f}dB', fontsize=9)
        axes[row, col + 1].axis('off')

plt.suptitle('人臉重建品質視覺比較 (不同 q 值)', fontsize=14, fontweight='bold')
plt.tight_layout()
plt.show()

```



0.0.22 3-5b. 邊緣個案 (Outlier) 分析

動機：從 3-5 的箱型圖中可觀察到 PSNR 分佈的離群點。本節找出在 $q=100$ 時 PSNR 最低的「難壓縮」人臉與最高的「易壓縮」人臉，進行視覺對照，並分析其奇異值結構差異，探討造成重建品質差異的原因。

```
[52]: # 以  $q=100$  時的 PSNR / SSIM 作為基準找出 outlier
q_ref = 100
# 重用 Section 3-5 已計算的 reconstructed_cache ( $q=100$  包含其中)
A_rec_ref = reconstructed_cache[q_ref]
clipped_ref = img_finalize(A_rec_ref)
psnr_ref = psnr(A_faces, clipped_ref, axis=-1) # shape: (400,)
ssim_ref = ssim_metric(A_faces, clipped_ref, axis=-1, img_shape=(64, 64))

# 找出 PSNR 最低的 3 張與最高的 3 張
n_outlier = 3
worst_idx = np.argsort(psnr_ref)[:n_outlier]
best_idx = np.argsort(psnr_ref)[-n_outlier:][::-1]

print(f"q={q_ref} 時 PSNR 最低的 {n_outlier} 張 (最難壓縮): ")
for idx in worst_idx:
    print(f" Face #{idx:3d} | 受試者 #{y[idx]} | PSNR={psnr_ref[idx]:.2f} dB | SSIM={ssim_ref[idx]:.4f}")

print(f"\nq={q_ref} 時 PSNR 最高的 {n_outlier} 張 (最易壓縮): ")
for idx in best_idx:
    print(f" Face #{idx:3d} | 受試者 #{y[idx]} | PSNR={psnr_ref[idx]:.2f} dB | SSIM={ssim_ref[idx]:.4f}")
```

```

# 視覺對照：原圖 vs q=100 重建
compare_idx = list(worst_idx) + list(best_idx)
labels = [f"難壓縮 #{i+1}" for i in range(n_outlier)] + [f"易壓縮 #{i+1}" for i
↳in range(n_outlier)]

fig, axes = plt.subplots(2, len(compare_idx), figsize=(3.5 * len(compare_idx),
↳7))

for col, (face_idx, lbl) in enumerate(zip(compare_idx, labels)):
    # 原圖
    axes[0, col].imshow(A_faces[face_idx].reshape(64, 64), cmap='gray', vmin=0,
↳vmax=255)
    axes[0, col].set_title(f"{lbl}\n受試者 #{y[face_idx]}", fontsize=8)
    axes[0, col].axis('off')
    if col == 0:
        axes[0, col].set_ylabel('原圖', fontsize=9, fontweight='bold')

    # 重建
    axes[1, col].imshow(A_rec_ref[face_idx].reshape(64, 64), cmap='gray',
↳vmin=0, vmax=255)
    axes[1, col].set_title(f"PSNR={psnr_ref[face_idx]:.
↳1f}dB\nSSIM={ssim_ref[face_idx]:.3f}", fontsize=8)
    axes[1, col].axis('off')
    if col == 0:
        axes[1, col].set_ylabel(f'q={q_ref} 重建', fontsize=9,
↳fontweight='bold')

plt.suptitle(f'邊緣個案對照 (q={q_ref})：難壓縮 vs 易壓縮', fontsize=14,
↳fontweight='bold')
plt.tight_layout()
plt.show()

# 分析各人臉的奇異值有效秩 (Effective Rank)
# 計算每位受試者 10 張人臉的 per-face SVD (使用中心化版本)
def singular_value_entropy(face_vec, mean_vec):
    """ 計算單張人臉矩陣 (64x64) 的歸一化奇異值熵作為複雜度指標。

    定義與 calculate_sve 保持一致：
    - 機率以能量 ( 2 ) 定義： $p_i = \frac{\sigma_i^2}{\sum_j \sigma_j^2}$ 
    - 歸一化分母使用全部奇異值數  $n_{total}$ ，衡量相對於整體維度的低秩性
    """
    img = (face_vec - mean_vec).reshape(64, 64)
    _, sv, _ = np.linalg.svd(img, full_matrices=False)
    n_total = len(sv)
    energy = sv ** 2
    # 過濾前保留全部維度數
    # 使用能量 ( 2 )，與 calculate_sve 一致

```

```

p = energy / np.sum(energy)
p_filt = p[p > 1e-12] # 排除數值零以避免 log(0)
entropy = -np.sum(p_filt * np.log(p_filt))
return entropy / np.log(n_total) if n_total > 1 else 0.0 # 分母用全維度數

entropies = np.array([singular_value_entropy(A_faces[i], mean_face_vec) for i
    ↪in range(400)])

print(f"\n奇異值熵分析 (0= 能量集中/易壓縮, 1= 分散/難壓縮) : ")
print(f" 難壓縮群 (PSNR 最低) 的平均熵 : {entropies[worst_idx].mean():.4f}")
print(f" 易壓縮群 (PSNR 最高) 的平均熵 : {entropies[best_idx].mean():.4f}")
print(f" 全體平均熵 : {entropies.mean():.4f}")
corr_entropy_psnr = np.corrcoef(entropies, psnr_ref)[0, 1]
corr_entropy_ssim = np.corrcoef(entropies, ssim_ref)[0, 1]
print(f" 熵值與 PSNR 的相關係數 : {corr_entropy_psnr:.3f}")
print(f" 熵值與 SSIM 的相關係數 : {corr_entropy_ssim:.3f}")
print("\n說明：單張影像的 2D 奇異值熵僅能作為『影像複雜度』的輔助指標；")
print("它與 dataset-level eigenfaces 重建誤差存在關聯，但不是嚴格的因果解釋。")

```

q=100 時 PSNR 最低的 3 張 (最難壓縮) :

Face #361		受試者 #36		PSNR=26.36 dB		SSIM=0.8617
Face #125		受試者 #12		PSNR=26.64 dB		SSIM=0.7971
Face #131		受試者 #13		PSNR=27.03 dB		SSIM=0.8635

q=100 時 PSNR 最高的 3 張 (最易壓縮) :

Face #187		受試者 #18		PSNR=32.32 dB		SSIM=0.9379
Face #144		受試者 #14		PSNR=32.02 dB		SSIM=0.9184
Face #242		受試者 #24		PSNR=31.94 dB		SSIM=0.9292



奇異值熵分析 (0= 能量集中/易壓縮, 1= 分散/難壓縮) :

難壓縮群 (PSNR 最低) 的平均熵 : 0.4749
 易壓縮群 (PSNR 最高) 的平均熵 : 0.4199
 全體平均熵 : 0.3893

熵值與 PSNR 的相關係數：-0.163

熵值與 SSIM 的相關係數：0.335

說明：單張影像的 2D 奇異值熵僅能作為『影像複雜度』的輔助指標；
它與 dataset-level eigenfaces 重建誤差存在關聯，但不是嚴格的因果解釋。

量化觀察與分佈分析：

- $q=1\sim5$ ：重建人臉僅保留整體輪廓和主要光影，無法辨認個人身份。此時 PSNR 分佈較為集中，因為整體細節皆嚴重遺失。
- $q=20$ ：已可看出人臉的基本特徵，但缺乏清晰的細節，平均 PSNR 約 23.6dB。此階段不同受試者間的品質差異開始顯現。
- $q=50$ ：臉部主要特徵（眼睛、鼻子、嘴巴）清晰可辨，平均 PSNR 接近 27dB。
- $q=100$ ：重建品質良好，平均 PSNR 接近 30dB 門檻。但觀察箱型圖可知，仍有部分受試者的 PSNR 低於 27dB，顯示個別差異顯著。
- $q=200$ ：平均 PSNR 超過 34dB，視覺上幾乎與原圖無異。此時大多數受試者皆已達到 30dB 以上的高品質重建。

不同受試者的個別差異：從 PSNR 分佈圖與最小值趨勢可以看出，在相同的成分數量 q 下，重建品質在受試者之間存在顯著差異（標準差隨 q 增加而略微擴大）。這表示某些受試者在前 q 個 eigenfaces 子空間之外仍保留較多殘差，因此需要更多成分才能達到與其他人相同的重建品質。單純依賴「平均 PSNR」可能會掩蓋這些個別重建品質極差的情況。

方法學補充：3-5b 使用的單張影像奇異值熵，可視為描述影像複雜度的輔助指標；它和重建難度通常有相關，但不應被解讀為 dataset-level eigenfaces 重建誤差的唯一成因。

0.0.23 3-5c. 簡易 1-NN 人臉辨識實驗

動機：Section 3-3 至 3-5 的分析均基於重建品質指標 (PSNR/SSIM)。然而，對人臉辨識而言，重建品質高不代表辨識效果好——過多的成分可能引入雜訊維度，反而降低判別力。本節以最簡單的 1-NN（最近鄰）分類器驗證 q 值對辨識準確率的實際影響。

```
[53]: # 1. 資料切分：每人前 5 張訓練（共 200 張），後 5 張測試（共 200 張）
train_mask = np.arange(400) % 10 < 5
test_mask = ~train_mask

X_train = A_faces[train_mask]
y_train = y[train_mask]
X_test = A_faces[test_mask]
y_test = y[test_mask]

# 2. 僅使用訓練集估計中心與特徵子空間（避免 data leakage）
mean_train = X_train.mean(axis=0)
X_train_centered = X_train - mean_train
X_test_centered = X_test - mean_train
_, _, Vt_train = np.linalg.svd(X_train_centered, full_matrices=False)

# 3. 實驗設定
q_values_recog = [1, 5, 10, 20, 30, 50, 80, 100, 150, 200, 300]
accuracies = []
```



```

# 向量化 1-NN：一次計算全部測試樣本到訓練樣本的距離

for q in q_values_recog:
    # 投影到前 q 個 Eigenfaces 空間
    # Vt_train[:q] 的每一列都是一個特徵向量
    W_q = Vt_train[:q].T # shape: (4096, q)

    train_proj = X_train_centered @ W_q # (200, q)
    test_proj = X_test_centered @ W_q # (200, q)

    dists = np.linalg.norm(test_proj[:, None, :] - train_proj[None, :, :],
        ↪axis=2) # (200, 200)
    preds = y_train[np.argmin(dists, axis=1)]
    accuracies.append(np.mean(preds == y_test) * 100)

# 4. 找出首次達標的最小 q 值
q_acc90 = next((q for q, acc in zip(q_values_recog, accuracies) if acc >= 90),
    ↪None)
q_95 = next((q for q, acc in zip(q_values_recog, accuracies) if acc >= 95),
    ↪None)

# 5. 繪圖
plt.figure(figsize=(10, 5))
plt.plot(q_values_recog, accuracies, 'b-s', linewidth=2, markersize=8, label='辨
    識準確率')
plt.axhline(y=90, color='r', linestyle='--', alpha=0.6, label='90% 門檻')
plt.axhline(y=95, color='g', linestyle='--', alpha=0.6, label='95% 門檻')
if q_acc90:
    plt.annotate(f'q={q_acc90} (Acc>=90%)', xy=(q_acc90, 90),
        ↪xytext=(q_acc90+10, 80),
        arrowprops=dict(facecolor='black', shrink=0.05, width=1,
        ↪headwidth=5))
if q_95:
    plt.annotate(f'q={q_95} (Acc>=95%)', xy=(q_95, accuracies[q_values_recog.
        ↪index(q_95)]),
        xytext=(q_95+10, 85), arrowprops=dict(facecolor='black',
        ↪shrink=0.05, width=1, headwidth=5))

plt.xlabel('保留成分數 q', fontsize=11)
plt.ylabel('準確率 (%)', fontsize=11)
plt.title('1-NN 人臉辨識準確率 vs q 值', fontsize=13, fontweight='bold')
plt.xticks(q_values_recog)
plt.grid(True, alpha=0.3)
plt.legend()
plt.show()


```



```
# 6. 輸出表格
data_62 = []
for q, acc in zip(q_values_recog, accuracies):
    data_62.append({
        'q 值': q,
        '準確率': acc / 100.0
    })

df_62 = pd.DataFrame(data_62)
styled_df_62 = (df_62.style.pipe(apply_report_theme)
    .format({'準確率': '{:.1%}'})
    .highlight_max(subset=['準確率'], props='background-color: #d4edda; color: #155724; font-weight: bold;')
    .set_caption("1-NN 辨識實驗摘要")
)
display(styled_df_62)

print(f"準確率首次達 90% 的最小 q : {q_acc90}")
print(f"準確率首次達 95% 的最小 q : {q_95}")
```



<pandas.io.formats.style.Styler at 0x118a75490>

準確率首次達 90% 的最小 q : None

準確率首次達 95% 的最小 q : None

0.0.24 3-6. 最終量化建議

根據以上分析，針對不同應用場景提出特徵向量數量建議：

應用場景	建議 q	依據
快速預覽 / 縮圖	$q = 20$	PSNR ~ 23.6 dB，輪廓可辨，壓縮比高
人臉辨識 (特徵提取)	$q = 50\sim 100$	實驗證實：準確率在此區間趨於飽和（詳見 Section 3-5c 實驗結果）
高品質重建	$q = 200$	本實驗中平均 PSNR 首次超過 30dB，且最小值也已超過 30dB
近乎無損重建	$q = 300$	平均 PSNR 約 40.9dB，視覺上已非常接近原圖

特徵數量選擇與辨識瓶頸分析：

- **辨識效能飽和與平台期 (Plateau)：**1-NN 辨識實驗顯示準確率在 $q=20$ 之後提升變得緩慢，且在 $q=100$ 之後即進入 87.5% 的平台期，始終未能達到 90% 門檻。
- **Data leakage 風險提醒：**若 PCA 使用「全部樣本 (含 test)」先估計特徵子空間，會讓辨識率被高估。此類設定下觀察到的 87.5% 應視為偏樂觀結果；改為嚴格 train-only PCA (本 notebook 已採用) 後，準確率通常只會持平或下降，不應期待因修正 leakage 而上升。
- **Eigenfaces + 1-NN 的 inherent limitation：**
 1. **訓練樣本受限：**每位受試者僅 5 張訓練樣本，難以覆蓋表情、視角與光影的極端變異，導致模型泛化能力受限。
 2. **高維空間的雜訊敏感性：**1-NN 分類器在維度增加時極易受到無關細節 (雜訊) 干擾。雖然增加 q 值能提升影像重建品質，但新增的奇異成分往往包含更多個人特有的細微雜訊而非具辨識價值的結構特徵，這在高維 Eigenface 空間中反而可能降低判別力。
 3. **PCA 的非判別性質：**Eigenfaces (PCA) 旨在最大化整體能量 (變異數)，而非類別間的區別度 (Discrimination)。當 q 值過大時，累積能量雖然增加，但對於「區分不同受試者」的邊際貢獻卻急劇遞減。
- **可行改進方向 (若目標是突破 90%)：**
 1. **Fisherfaces / LDA：**在 PCA 降噪後再做 LDA，直接優化類別可分性。
 2. **距離度量學習：**以 Mahalanobis 類度量 (或其學習版) 取代固定歐氏距離，提升最近鄰判別力。
 3. **分類器升級與驗證：**使用 k -NN ($k>1$)、SVM 或正則化分類器，並透過交叉驗證調整 q 與超參數。
- **重建品質：**相較於辨識率的快速飽和，PSNR 隨 q 增加呈現穩定的線性增長。平均 PSNR 30dB 仍需 $q=200$ 才能確保所有樣本的視覺還原度。

綜合建議：人臉辨識特徵提取建議選取 $q = 50\sim 100$ ，此時已捕捉絕大部分具辨識價值的結構；若應用強調「視覺還原」而非「機器辨識」，則建議使用 $q = 200$ 。

0.0.25 Section 1 : PCA 與 SVD 的差異與等價性

Eckart-Young 定理數值驗證：實驗計算的 Frobenius 誤差 $\|A - A_q\|_F$ 與理論值 $\sqrt{\sum_{i>q} \sigma_i^2}$ 的最大差值完全符合 float64 數值精度。定理得到完美的數值驗證，確認截斷 SVD 是最優低秩近似。

PCA 與 SVD 等價性驗證：在對中心化矩陣操作的前提下，手動 PCA 的重建結果與 SVD 重建的差值 $< 10^{-8}$ ，等價性得到嚴格數值驗證。

0.0.26 Section 2 : Patching 的效應

Patching 的優勢區間：在將 patch mean 的儲存成本納入壓縮比後，高壓縮比下仍以較小 patch 較有優勢，而大 patch 的可達壓縮倍率會明顯下降。最佳 patch size 依然會隨目標壓縮比改變，但比較時必須使用修正後的壓縮比公式。

0.0.27 Section 3 : 人臉資料的特徵向量選擇

能量與分佈分析：人臉資料集的能量極度集中。除了觀察「平均 PSNR」外，本次實驗新增了 **分佈分析（標準差與最小值）**。結果顯示，受試者間存在顯著的重建品質差異。若要確保所有受試者皆獲得良好重建，本 notebook 的實驗結果支持使用 $q \approx 200$ ；而 $q = 50 \sim 100$ 最多只能作為後續辨識實驗的候選起點，不能直接視為最佳辨識特徵數。在分類任務中，Fisher 準則 (LDA) 或交叉驗證的辨識準確率，會比 PCA 的重建 PSNR 更有意義。